受控干预启发的极化与区域证据学习用于跨场景 SAR 船舶分类

Mo Yu, Xiangguang Leng, Member, IEEE, Qihao Huang, Jilong Li, and Kefeng Ji, Member, IEEE

[1]

摘要

跨场景 SAR 船舶分类面临局部判别证据随场景变化而改变的问题。在中低分辨率图像中，同一船只的局部响应排列会随观测改变，邻域信息也可能补充或干扰船型判断。本文通过重复船舶观测、区域输入对照和受控图像干预，发现局部尺度响应的判别作用依赖极化、区域及联合读出方式，部分纠错来自削弱竞争类别。基于这些发现，提出共享 ResNet-50 骨干的极化与区域证据网络：类别响应反馈模块保留均值上下文并利用相对类别响应调节局部特征；响应引导区域池化模块在目标几何区域内组织多层判别证据；参考类别证据回写模块将查询与源参考的比较转化为中间层类别证据场。训练采用受控干预选样与判别优势保护约束。在 OpenSARShip 1.0 和 2.0 四分类任务中，完整模型相对同协议普通骨干的三种子平均 OA 分别提高 10.053 和 5.115 个百分点，BA 分别提高 4.985 和 3.454 个百分点。OpenSARShip 2.0 的配套消融表明，区域池化带来 OA 4.762、BA 3.466 个百分点的增量；局部替换与原图案例进一步揭示类别响应和参考回写参与决策的方式。结果支持通过保留极化与区域身份、组织类别竞争证据改善跨场景分类。

关键词： SAR 船舶分类；跨场景泛化；双极化；区域池化；参考证据；受控干预

1 引言

SAR 船舶分类位于目标检测之后，依据有限的船体外形、局部响应和周围结构区分外观相近的船型。OpenSARShip 等资源推动了 Sentinel-1 船舶解译研究 [1]。然而，训练与应用数据来自不同过境或水域时，同类乃至同一艘船的可见证据也会改变。本文研究包含不同采集时相、观测条件及港口水域的跨场景 SAR 船舶分类，评价模型在上述因素共同变化时的识别能力。场景由采集产品所属过境、成像条件和地理水域共同描述，涵盖同港不同采集和不同港口 / 水域之间的迁移。实验通过产品元数据确定过境组，并同时隔离船舶身份；该划分评价实际场景差异下的识别能力，不将混合变化归因于单一港口或角度因素。

图 1 展示三艘船在不同场景中的方向、强响应排列与 VV/VH 差异。其中化学品/成品油轮的两次观测来自同港、同平台，表明同港采集之间也存在显著变化。同船诊断进一步显示，原油轮较多出现一次正确、一次错误，普通货船则更多持续混淆。这些差异提示应结合类别与实际局部响应研究失效机制。

[1]This work was supported in part by the National Natural Science Foundation of China under Grant 62471475, in part by Hunan Provincial Natural Science Foundation of China under Grant 2024JJ4045, and in part by the Science and Technology Innovation Program of Hunan Province under Grant 2024RC3124. M. Yu, X. Leng, Q. Huang, J. Li, and K. Ji are with the College of Electronic Science and Technology, National University of Defense Technology, Changsha 410073, China. Corresponding author: Xiangguang Leng (e-mail: luckight@163.com).

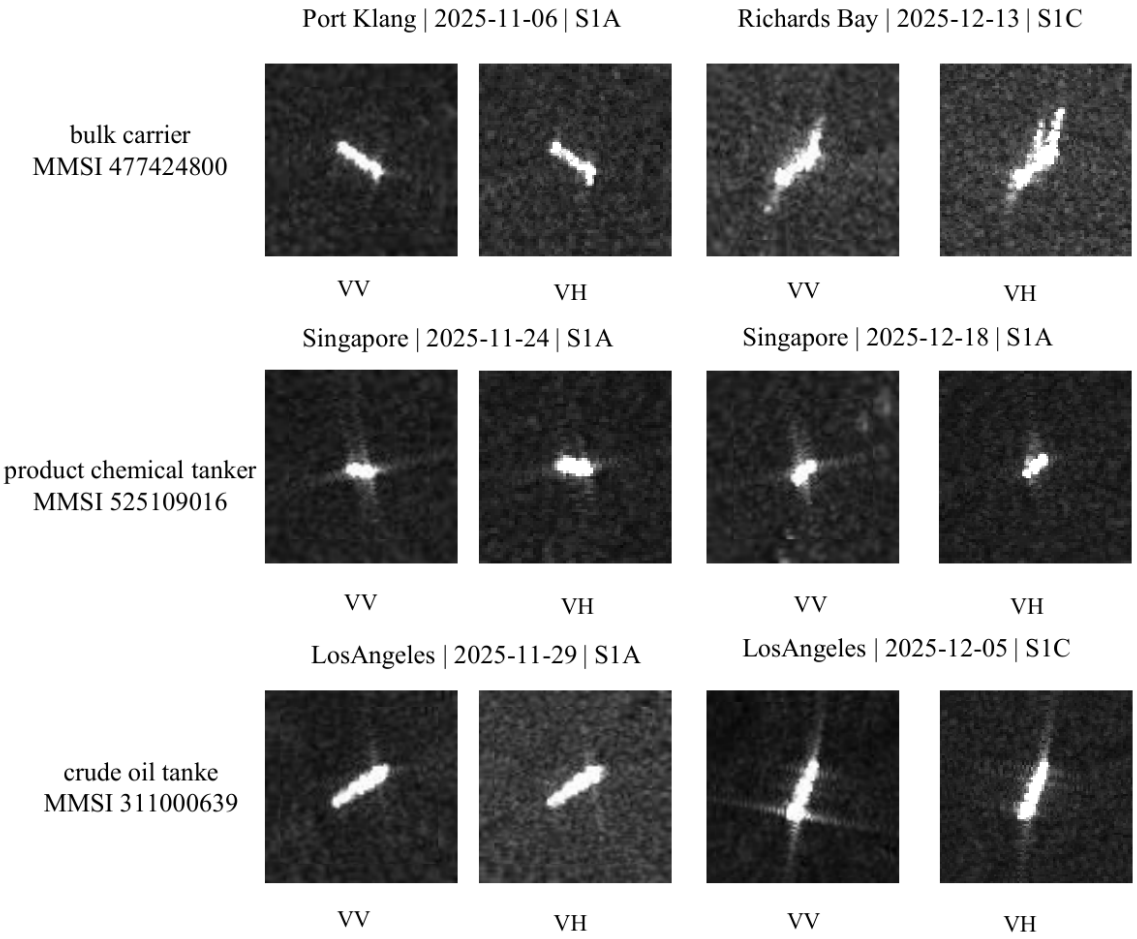


图 1 24 港数据中三艘船的配对观测。三行依次为散货船、化学品/成品油轮和原油轮；每行展示同一船舶在两次过境中的 VV/VH 图像，标注对应港口、日期、卫星平台与 MMSI。

现有双极化方法通过共享特征提取、多尺度融合或极化交互提升船舶表征 [2,3,4]。近年的研究进一步利用极化与纹理构造表示 [5]、多尺度域对齐 [6] 以及目标区域引导的多模态融合 [7] 改善船型分类。本文进一步关注这些表征中的证据如何被利用：同样的局部响应，位于框内与框外、来自 VV 与 VH、支持不同竞争类别时，是否具有相同价值？如果框外响应中包含可用线索，直接剔除会造成信息损失；如果不加区分地汇总，误导性响应又可能与有效证据混合。局部高响应不自动等于正确类别证据，低响应也不自动等于噪声。

为此，我们将自然观测与受控输入干预结合。前者揭示实际分类不稳定，后者固定模型和参考条件，仅改变一个极化、区域和尺度分量，追踪正确类别与竞争类别的分数变化。本文研究的是指定输入操作在分类系统中的判别效应。依据输入敏感性与训练后信息价值的区别 [8,9]，进一步通过配套训练和算子替换检验这些线索能否转化为分类收益。

本文的贡献包括三个方面：（1）结合同船观测、区域输入控制与极化—区域—尺度干预，揭示局部响应对类别竞争的条件性作用，为保留差异化证据提供依据；（2）提出类别响应反馈模块（Class-Response Feedback Block，CRFB）、响应引导区域池化模块（Response-Guided Regional Pooling，RGRP）和参考类别证据回写模块（Reference-Class Evidence Writeback，RCEW），分别作用于局部特征形成、区域汇总和跨样本证据引入；（3）通过配套训练、空间对应替换和实际船舶案例，验证类别响应引导取证及参考类别证据回写的作用。

2 相关研究

2.1 SAR 船舶分类与跨场景泛化

OpenSARShip 面向 Sentinel-1 船舶解译建立开放数据资源 [1]；FUSAR-Ship 基于高分三号 SAR 与 AIS 匹配支持检测和识别 [10]。不同资源在传感器、分辨率、类别体系和样本组织上存在差异。针对分布差异，已有研究将双分支注意与深度子域适应用于 SAR 船型分类 [11]。本文以局部判别证据的组织补充分布适配研究，并以船舶身份及过境组隔离建立跨场景评价。

MSADAN 结合尺度感知特征、多层双线性融合驱动的对抗对齐及类别对比约束，处理多分辨率 SAR 船型跨域分类 [6]。Shi 等在有标签光学源域到无标签 SAR 目标域的迁移中联合域级校准与类级对齐 [12]。这些方法分别关注分辨率变化和跨模态适配；本文研究源 SAR 监督下，局部响应的极化、区域身份及源参考类别关系如何参与跨场景判断。

2.2 双极化、类别响应与分层证据

HOG-SiamShipCLSNet 采用共享骨干提取 VV/VH 特征，并在不同深度结合组双线性池化及 HOG 描述 [2]。DPIG-Net 使用 VV 引导 VH 与极化乘积幅度分支，通过交叉注意及残差融合组织极化信息 [3]。CPINet 结合多尺度融合、混合阶统计注意与因子化双线性编码 [4]。这些研究表明共享或专属处理、跨极化交互和高阶统计均已有方法基础。

DBDN 构造极化特征引导和纹理特征引导的两种伪 RGB 图像，进行双分支提取与融合分类 [5]。本文采用逐极化前向与共享卷积，并以极化专属类别响应连接中间特征处理和区域取证。

SCRC-Net 的结构约束融合模块从特征预测采样网格的长宽、共同旋转角与局部伸缩，以适应细长船体结构 [13]。本文利用检测 OBB 定义目标相对区域，保持框内、轴端与侧向的证据身份，再由类别响应指导区域内汇总。两者分别从采样几何和证据读出组织结构信息。

PGMNet 从 SAR 图像生成目标掩膜，以掩膜引导视觉特征对齐，并融合船舶尺寸描述的文本表征 [7]。本文 RGRP 保留船体与不同方向外围的区域身份，RCEW 引入带类别的源参考，使目标几何与跨样本判别关系分别承担区域定位和类别比较的作用。

类别响应与统计反馈方面，CAM 将线性分类权重投射到末层卷积图，生成类别相关空间响应 [14]；SENet 以全局均值生成通道权重 [15]，SRM 联合均值和标准差完成重标定 [16]，GSoP 将通道或位置二阶统计嵌入中间层反馈 [17]。本文 CRFB 保留均值支路，通过相对候选类别响应与局部值的交叉统计产生位置相关反馈，并将响应继续传递给 RGRP，用于区域内部取证。

区域上下文方面，A2-Nets 将注意汇总的全局描述按位置重新分配 [18]；GCNet 通过瓶颈变换将全局上下文反馈至特征图 [19]；R-FCN 以位置敏感得分图与 RoI 网格编码类别及相对位置 [20]。RGRP 以 OBB 框内、轴端和侧向限定证据来源，分别进行区域回写与多层读出，并复用 CRFB 响应指导浅层取证。

SAA 从原图及随机裁剪中选择查询—支持最匹配的特征，联合估计空间和通道注意后进行原型分类 [21]。本文在目标几何区域内复用候选类别响应，检验类别相关评分相对一般内容注意的取证效用。

2.3 局部参考比较与类别证据

Prototypical Networks 依据查询到类内支持均值原型的距离分类 [22]；DN4 将同类参考组成局部描述池，累加查询的近邻相似度 [23]；CAN 通过类参考与查询的相关性生成交叉注意，比较加权表示 [24]。这些工作分别提供全局原型、局部到类度量与查询相关取证的依据。

DeepEMD 通过交叉参考机制为密集表示中的结构元素赋权，并以局部匹配完成少样本分类 [25]；FRN 使用类内参考局部特征重构查询图，以岭回归重构误差形成类别分数 [26]。两者为局部参考利用提供了不同途径。本文借鉴关系算子，在已知类别和固定源参考库的闭集任务中研究中间层证据回写。

BiEnFRN 联合支持—查询双向重构、自重构与快照集成，提高细粒度少样本分类的区分能力 [27]。

与 SAA 的联合注意 [21] 和重构式分类相比，本文 RCEW 将查询相对于各参考类别的距离转化为类别证据场，回写至中间特征，由后续骨干继续处理。

RCEW 保留参考权重、区域身份和类别组织，以传输边际聚合参考值，再形成查询相关的类间证据。回写消息显式包含类别比较结果，使后续网络直接处理参考提供的判别信息。其与普通参考特征回写、精细局部对应的差异通过内部替换实验检验。

2.4 受控扰动与解释约束

Li 等在 SAR 自动目标识别中量化目标、阴影与杂波的贡献及交互，并通过背景重标度研究非目标区域依赖 [28]。Meaningful Perturbation 通过显式输入操作研究固定模型的重要区域 [8]；ROAR 在训练和测试数据中一致移除信息后重新训练，强调区分模型敏感性与信息价值 [9]。Fourier Perspective 通过范数受控的频率扰动分析鲁棒性，说明高频或低频的作用不能一概而论 [29]。Right for the Right Reasons 则将解释约束纳入可微训练 [30]。

本文将受控输入分析细化为极化、目标相对区域和空间尺度，并同时记录正确类与竞争类变化。源端干预响应用于筛选判别优势保护对象，使训练约束与样本实际响应相联系。

在训练端，RSC 依据真实类梯度抑制主导隐藏特征，鼓励网络利用其他证据 [31]；输入梯度正则直接约束分类损失对输入的局部敏感性 [32]。本文比较有限幅度的区域尺度操作与匹配均值控制，对通过判别改善筛选的源样本施加教师分差下界保护。

PASTA 依据合成与真实图像的幅度谱差异，对较高空间频率施加相对更强的乘性扰动，以扩大训练分布覆盖 [33]。FGFL 根据少样本任务产生 DCT 频率掩膜，转换回图像后结合三元组与对比目标学习表示 [34]。本文的尺度操作同样发生于图像，但以极化、区域和类别竞争的操作效应确定保护对象；预测路径仅使用空间特征。

Contrastive-ACE 利用特征对标签的平均干预效应稳定性组织跨域学习 [35]。本文从可追溯的输入操作出发，以正确类—竞争类分差刻画响应变化，并将其用于样本级判别保护。

3 问题发现与受控干预证据

3.1 从自然不稳定到可检验问题

同船诊断使用自建 24 港语料中的 4744 次观测、2973 个船舶身份、18 港及八个输出类别。对每艘具有重复观测的船选择日期跨度最大的一对，得到 910 艘船的 1820 次观测，覆盖七类。表 1 给出三种代表性船型的三种子平均状态比例。

表 **1** 同船重复观测的分类状态，三种子平均。

船型	船对数	两次均正确（%）	一次正确一次错误（%）	两次均错误（%）
集装箱船	126	35.98	34.92	29.10
原油轮	100	27.67	54.67	17.67
普通货船	62	4.84	27.42	67.74

原油轮较多表现为观测相关的不稳定，普通货船则更多持续混淆。跨港与同港的粗比较还受到类别组成影响：未经类别等权，跨港 “两次均错误” 比例为 38.80%，低于同港 43.92%；按七类等权后分别为 50.94% 和 46.06%，方向反转。因此，任务需同时关注观测条件与类别组成，不能把跨港分组差异直接解释成港口的独立效应。

在相同源划分和配套训练的 Ridge 读出下，整图输入与卷积前框内掩膜输入的 OA/BA 分别为 35.139%/38.795% 和 32.610%/37.231%；原油轮召回分别为 53.580% 和 42.222%。整图输入在 4744 条观测中纠正 690 条、误判新增 570 条，净增加 120 条正确判断。这表明外围可见响应包含可利用的补充信息，也具有误导风险，需要区分其对具体类别竞争的作用。

3.2 干预定义与类别竞争

记双极化输入为 $x = (x^{VV}, x^{VH})$，固定诊断器为 T，真实类别为 y。以原图最强错误类作为固定竞争类别 $c^\star = \arg\max_{c \neq y} T_c(x)$，定义分差及操作效应：

$$\begin{aligned} m_{y,c^\star}(x) &= T_y(x) - T_{c^\star}(x), \\ \Delta m_a &= m_{y,c^\star}(x_a^I) - m_{y,c^\star}(x). \end{aligned} \tag{1}$$

其中 $a = (p, r, b)$ 指定极化 p、区域 r 和尺度 b。图像尺度分量取

$$D_f(I) = I - G_1(I), \qquad D_m(I) = G_1(I) - G_2(I). \tag{2}$$

G_σ 为标准差为 σ 个原生像素的高斯平滑。限定区域内通过平滑边缘掩膜削弱分量，保持另一极化、检测框、参考库和模型参数不变。结构操作使用共同 L_2 剂量，并设置具有相同区域净灰度变化的均值控制，以区分局部结构变化和平均亮度变化的作用。

式（1）可分解为 $\Delta T_y - \Delta T_{c^\star}$。因此，正确类分数下降并不必然意味着决策退化：如果错误竞争类下降更多，分差仍可改善。为排除竞争类切换造成的虚假改善，选样时进一步检查各自最强错误类定义的分差 $m_{\max}(x) = T_y(x) - \max_{c \neq y} T_c(x)$。

3.3 极化与区域决定操作效应

在自建 24 港语料的 104 艘船、209 次观测、31 个过境和 6 港干预队列中，VH 框内细尺度削弱平均损害正确类别优势，VH 侧向中尺度削弱平均改善优势，同一侧向中尺度操作在 VV 中则为负。表 2 以诊断器分差报告效应及船级 95% 区间。

表 **2** 极化与区域干预的船均分差变化。

操作	平均 Δm	船级 95% 区间	相对同均值控制的剩余效应
VH 框内细尺度削弱	−0.003910	[−0.005232, −0.002528]	−0.002997
VH 侧向中尺度削弱	+0.002023	[+0.000882, +0.003169]	+0.001417
VV 侧向中尺度削弱	−0.001454	[−0.002477, −0.000476]	−0.001147

类别进一步调节操作效应：VH 侧向中尺度削弱在 9 艘集装箱船上的平均分差变化为 +0.008422，在 7 艘散货船上为 −0.008180。相反的作用方向支持保留极化和区域身份，并依据类别响应学习取证方式。

3.4 判别作用依赖联合读出

OpenSARShip 1.0 的 175 艘集装箱船、203 次观测提供了联合读出对照。同一 VH 框内细尺度削弱，在 VV/VH 联合读出中的平均分差变化为 +0.001596，在单 VH 读出中为 −0.000700；两者差为 +0.002296，船级 95% 区间为 [+0.002039,+0.002583]，覆盖的 20 个过境均同向。

在全部 1165 条扩围观测上统一执行该 VH 操作，产生 3 次纠错和 8 次误伤，OA 下降 0.429 个百分点。因而，联合读出效应提示的是条件化利用局部响应，而非固定预处理。

图 2 的散货船 10488 展示了类别竞争的变化。仅削弱 VH 框内细尺度后，散货分数增加 0.11492，错误原油轮分数下降 0.16278，分差提高 0.27769；均值控制仍误判。对照案例化学品船 26628 则同时降低正确类并抬高海工竞争类，产生误伤。局部证据的效用因此需落实到正确类与竞争类的相对变化。

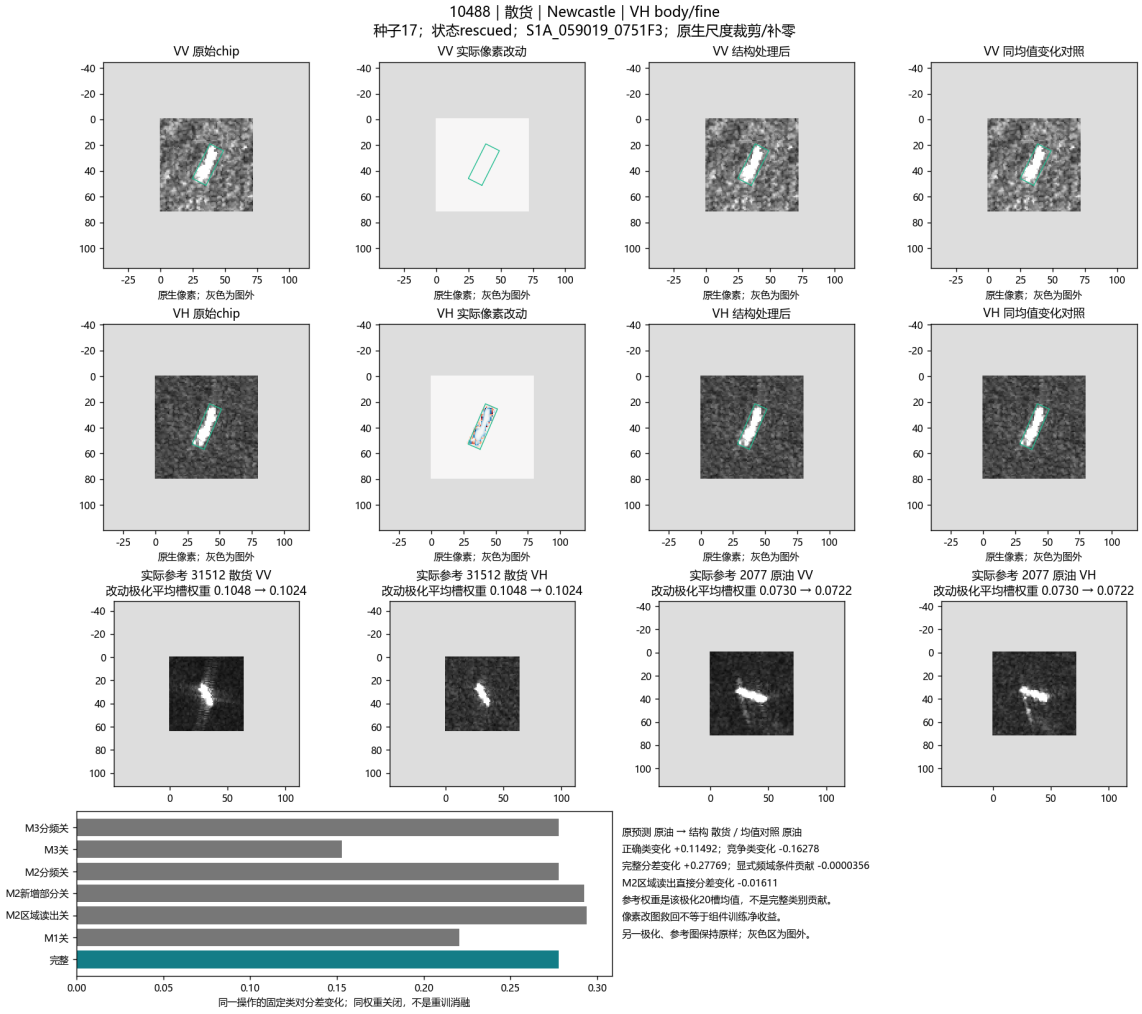


图 2 散货船 10488 的受控干预与实际参考。VV 保持不变，VH 框内细尺度削弱改变类别竞争；匹配均值控制仍误判。结果来自固定诊断模型。

3.5 判别机制与设计依据

固定模型上的输入操作建立了“局部响应变化—类别竞争变化”的可追溯联系。该机制描述分类系统对指定操作的依赖；自然观测中的方向、海况和目标状态则共同影响输入。本文据此形成三项设计要求：保留均值信息与相对类别响应，区分极化和几何区域的证据来源，将源参考转换为可被后续网络处理的类间判别信息。三者分别落实为 CRFB、RGRP 和 RCEW，并由配套训练及替换实验检验。

4 方法

4.1 任务与整体结构

给定固定检测流程定位的目标 chip、OBB 与极化可用性标记，模型预测 K 个已知船型之一。网络在源场景的标注样本上学习，在船舶身份和采集过境均隔离的目标场景中评价。公开集分类实验取 $K = 4$，自建数据诊断采用八类标签。源参考库为 $\mathcal{R} = \{(x_j, y_j)\}_{j=1}^{B}$，取 $B = 32$，每类 8 个参考。查询标签不参与预测；参考选择排除与查询同船或同过境的观测，并按极化可用性屏蔽无效关系。

输入按目标中心在原生像素网格裁剪或补零至 160×160，保留已有 chip 的像素尺度，有效范围掩膜排除补零。VV 与 VH 分别前向并共享 ResNet-50[36] 卷积权重；CRFB、RGRP 及 RCEW 的投影与回写使用极化专属参数，生成通道度量的小网络共享。各极化依据检测框有效性确定是否进入分类：某一极化未通过目标定位或置信度要求时，仅屏蔽该分支，仍使用另一有效极化。这对应检

测后分类中部分极化定位失败的情况，原始影像本身可同时具备 VV 和 VH。

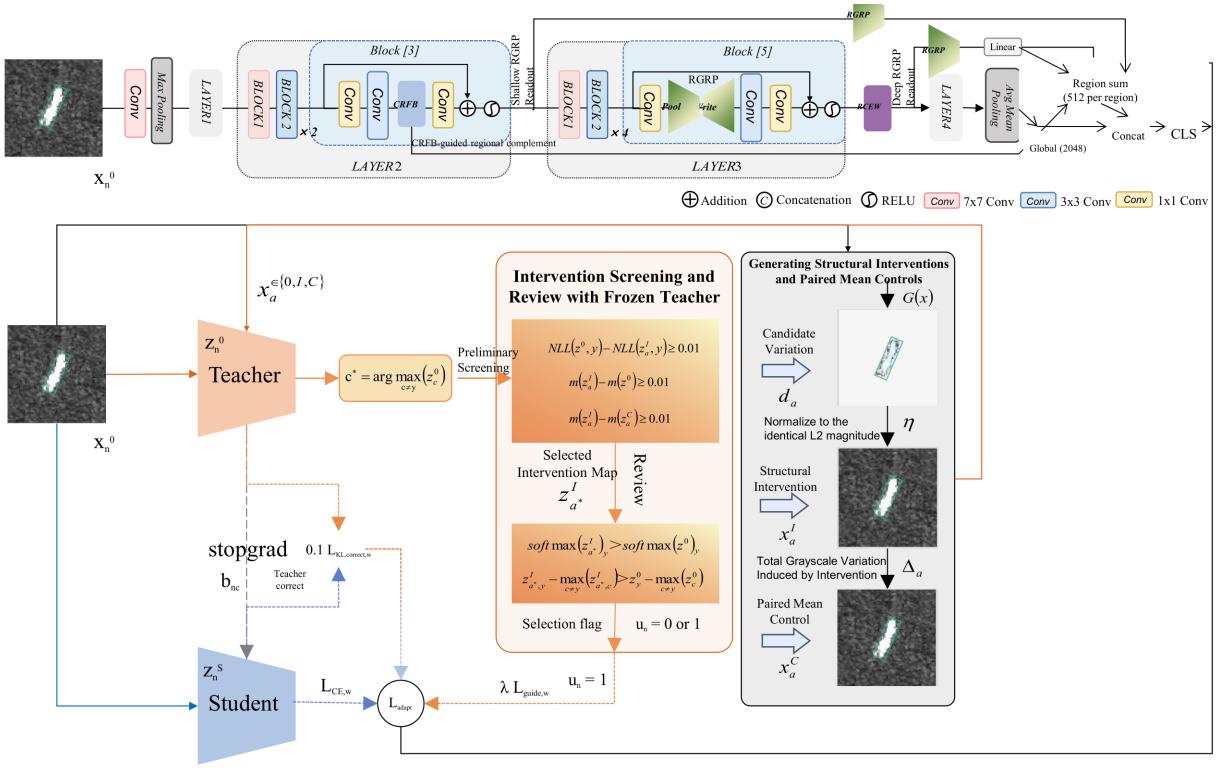


图 3 整体结构及受控训练路径。两极化共享骨干、使用专属证据处理参数；同一区域的多层摘要相加，再与全局描述拼接。RCEW 读取源参考。下部为训练框架中的干预选样和判别保护路径，预测时仅执行上部网络。

CRFB 位于 layer2 末块的 conv2 激活之后；RGRP 在 layer3 末块的 conv1 激活后执行区域池化回写，并从 layer2 输出和 RCEW 更新后的 layer3 输出读取区域摘要；RCEW 位于 layer3 与 layer4 之间。各极化分别执行上述处理，全局描述来自 layer4。区域池化保持特征图空间尺寸，与骨干下采样各司其职。

4.2 类别响应反馈模块（CRFB）

设某一极化的输入为 $X_1(u) \in \mathbb{R}^{128}$，$u$ 表示空间位置，有效面积占比为 $o(u)$，归一化权重为 $\omega(u) = o(u)/\sum_v o(v)$。屏蔽无效位置后，以两个 1×1 卷积得到 32 维值特征 $V_1(u)$ 和 K 维候选类别响应 $A(u)$。记 $\bar{V}_1 = \sum_u \omega(u) V_1(u)$，相对类别响应及其标准化量为

$$
\begin{aligned}
d_k(u) &= A_k(u) - \frac{1}{K-1} \sum_{j \neq k} A_j(u), \\
\bar{d}_k &= \sum_u \omega(u) d_k(u), \\
s_k(u) &= \frac{d_k(u) - \bar{d}_k}{\sqrt{\sum_v \omega(v)(d_k(v) - \bar{d}_k)^2 + 0.01}}.
\end{aligned}
\tag{3}
$$

以相对响应和局部值的共同变化形成类别相关摘要：

$$
\begin{aligned}
C_k &= \sum_u \omega(u) \left[V_1(u) - \bar{V}_1 \right] s_k(u), \\
R_1(u) &= \frac{1}{K} \sum_k \tanh(s_k(u)) \tanh(L_k(C_k)).
\end{aligned}
\tag{4}
$$

C_k 描述低维内容与标准化类别响应之间的交叉统计，L_k 为含偏置的仿射映射。令均值变换 $U_0 = W_0 \tanh(L_0(\bar{V}_1))$，与关系支路共同生成有界门控并反馈至原特征：

$$
\begin{aligned}
G_{\mathrm{CRFB}}(u) &= o(u) \tanh\{U_0 + W_1 R_1(u)\}, \\
X_1'(u) &= X_1(u) + 0.3 X_1(u) \odot G_{\mathrm{CRFB}}(u).
\end{aligned}
\tag{5}
$$

输出映射零初始化，使训练从原特征路径开始。类别辅助读出利用源标签约束候选响应。X_1' 经过该 block 的 conv3、归一化与残差相加形成 layer2 输出 F_2；类别响应保留给后续区域读出使用。

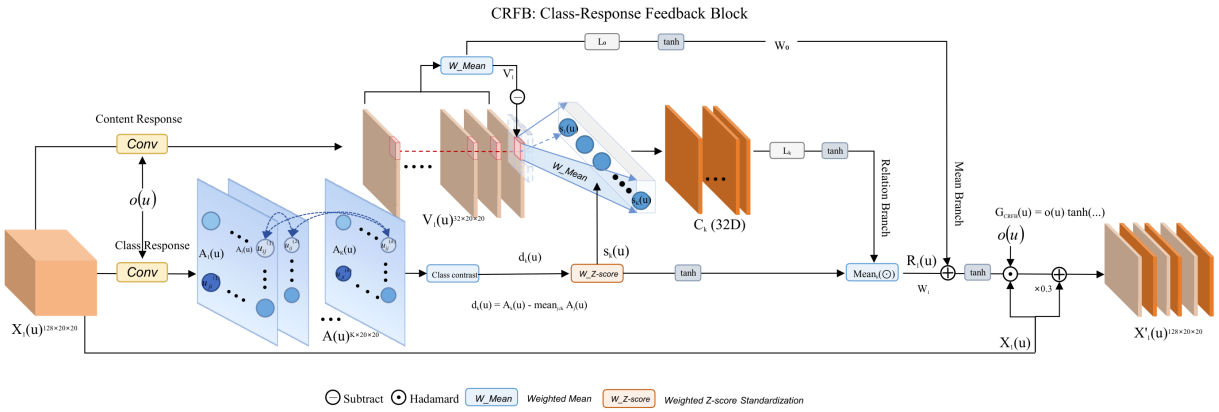


图 4 CRFB。内容均值与类别响应—内容交叉统计 C_k 分别变换，形成局部门控。反馈增益为 0.3，有效面积占比屏蔽补零位置。

均值支路保留整体上下文，式（4）进一步表示响应偏离与局部内容的共同变化，使门控随类别证据的空间分布而变化。

4.3 响应引导区域池化（RGRP）

4.3.1 区域身份与内部回写

以 OBB 长轴建立目标相对坐标，构造框内、轴端与侧向三个区域。框内为长宽 L, W 的软矩形；轴端为长轴扩展至 $1.5L$ 的矩形减去框内；侧向为宽度扩展至 $2W$ 的矩形减去框内。区域与有效输入范围相交，以特征网格实际面积占比表示 $m_r(u)$。两轴端对称处理，无需船首、船尾标注。

对于特征 F，区域均值为

$$
\pi_r(u) = \frac{m_r(u)}{\sum_v m_r(v)}, \qquad \mathrm{Pool}_r(F) = \sum_u \pi_r(u) F(u). \tag{6}
$$

令 $t_r = \mathrm{Pool}_r(X_3)$。空区域返回零并屏蔽更新。layer3[5] 中的内部 RGRP 以区域专属两层映射 ϕ_r 变换摘要，只回写至相应区域：

$$
\begin{aligned}
X_3'(u) &= X_3(u) + \sum_r \widetilde{m}_r(u) \phi_r(t_r), \\
\widetilde{m}_r(u) &= m_r(u) / \max\{1, \sum_j m_j(u)\}.
\end{aligned}
\tag{7}
$$

其中 X_3 为 conv1 激活后的 256 通道特征。区域上下文回写保持空间尺寸，使随后 3×3 卷积同时读取局部内容与相应区域的摘要。另两处区域读出仅汇总特征，用于最终分类。

4.3.2 由 CRFB 响应指导浅层取证

CRFB 读取 layer2[3] 中的 128 通道特征，其响应与该 block 末端 512 通道特征 F_2 位于同一 20×20 网格。在有效范围内标准化相对类别响应，得到有界评分 $q_k(u) = 2\tanh(s_k(u))$。在每个区域内分别归一化：

$$\begin{aligned} \alpha_{r,k}(u) &= \frac{m_r(u)\exp q_k(u)}{\sum_v m_r(v)\exp q_k(v)}, \\ t_{r,k} &= \sum_u \alpha_{r,k}(u) V_2(u). \end{aligned} \tag{8}$$

其中 $V_2 = W_V^{(2)}\,\mathrm{LN}(F_2)$ 为 512 维到 32 维的值投影。同时保留均匀摘要 $t_{r,0} = \sum_u \pi_r(u) V_2(u)$；四类时五个摘要拼接为 160 维。记 $t_r^{\mathrm{cat}} = [t_{r,0}; \ldots; t_{r,K}]$，$\sigma_{p,r} = \mathrm{stopgrad}\{\mathrm{RMS}(\mathrm{Pool}_r(F_{2,p}))\}$，补充量为

$$\delta_{p,r}^{(2)} = 0.1\sigma_{p,r}\tanh(W_p^{\mathrm{read}} t_r^{\mathrm{cat}}). \tag{9}$$

W_p^{read} 将 160 维映射回 512 维，零初始化，同一极化的三区域共享该映射。所有候选类别同时参与，既不输入查询真值，也不按当前预测的单一类别硬路由。输出仍位于原有区域槽位，保留均值信息，并用有界残差限制新增路径的幅度。式（8）回答“在这一几何区域内哪些位置更有助于类别区分”，式（6）回答“该区域总体包含什么”。

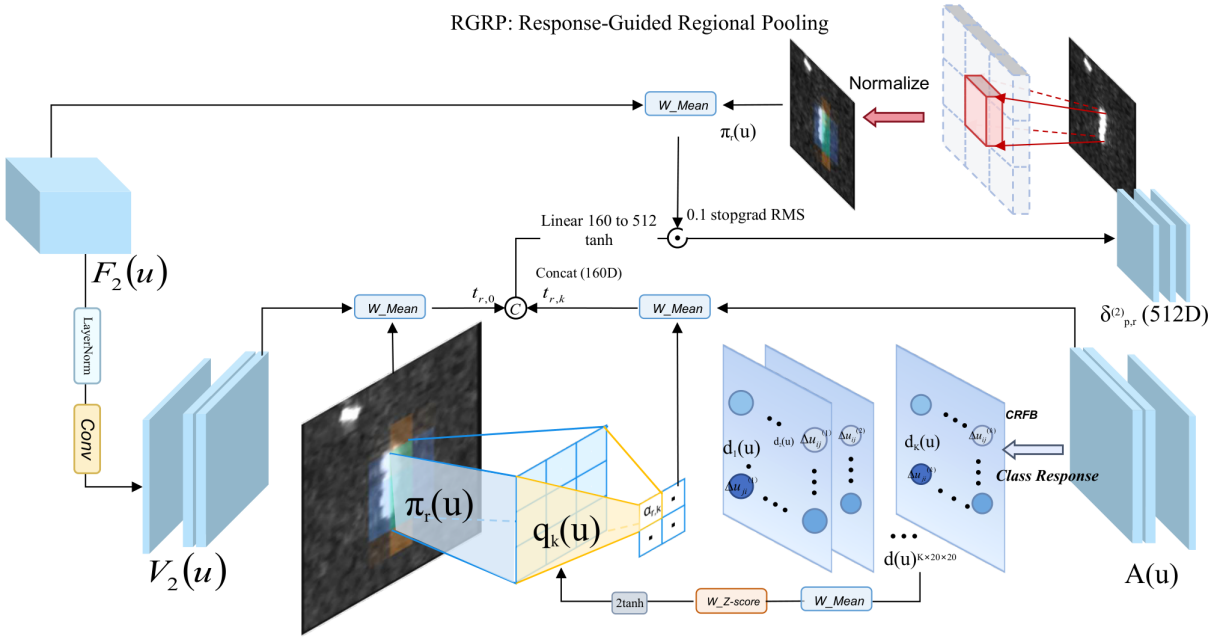


图 5 CRFB 引导的 RGRP 浅层读出。类别响应 $A(u)$ 与内容投影 $V_2(u)$ 在区域内联合取证；均值及类别加权摘要拼接，经 160 到 512 维映射形成有界补充量。区域归一化权重为 π_r。

区域权重依据特征中心的覆盖面积计算；由于卷积感受野交叠，区域描述保留的是计算位置与目标几何的关系。

4.4 参考类别证据回写（RCEW）

4.4.1 比较描述与值描述分离

RCEW 使用源参考库补充单图判别。首先对固定锚点路径中的 layer1 和 layer2 特征分别读出区域局部描述，通道数为 256 和 512。每极化各自投影至 32 维并拼接，再分别生成 32 维比较键 k 与值

v。键经归一化用于比较，值用于构造判别消息。局部槽位保留框内 8、侧向 8、轴端 4 的组织，空槽和不可用极化不参与参考比较。

参考比较使用固定锚点路径的 layer1 和 layer2 表示，以在读出优化期间保持查询—参考表征一致。

对某区域的合法源参考，按参考标签形成类均值 μ_c 和其他类均值 $\mu_{\neg c}$，记 $a_c = [\mu_c; \mu_{\neg c}; \mu_c - \mu_{\neg c}]$，由共享小网络生成有界正通道度量：

$$w_c = 1 + 0.5 \tanh \psi(a_c),$$
$$S_{sij} = \cos(\sqrt{w_{y_s}} \odot k_i^q, \sqrt{w_{y_s}} \odot k_{sj}^{\mathrm{ref}}). \tag{10}$$

这里 i, j 分别是查询与参考的局部槽位，s 是参考船，y_s 是已知源标签；为简洁省略极化和区域索引。通道分支以 32 维类均值、其他类均值及其差拼接为 96 维，经 96→16→32 的小网络生成 $w_c \in (0.5, 1.5)^{32}$。它既用于键的加权余弦比较，也用于后续值距离，并非独立的分类头。

空间分支先计算查询槽位对类别 c 的最佳相似度 $B_{ic} = \max_{s:y_s=c,j} S_{sij}$，只在合法参考和非空槽位上取最大值。再以 $b_{ic} = B_{ic} - \mathrm{mean}_{c' \neq c} B_{ic'}$ 表示相对其他可用类的优势，形成比较 logit $L_{sij} = S_{sij} + b_{i,y_s}$。只有一个可用类别时令 $b_{ic} = 0$。带未匹配槽的 Sinkhorn 归一化产生有效传输 T_s，非法位置在归一化前屏蔽。通道与空间分支因此是耦合的比较步骤，而不是两个结果直接相加的独立分支。

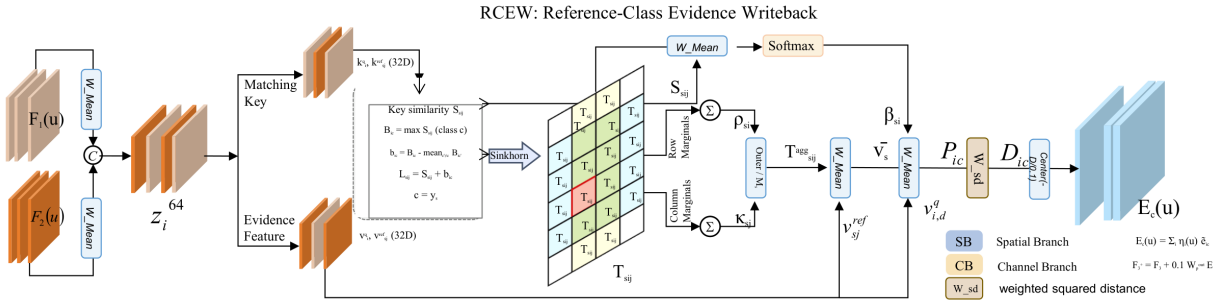


图 6 RCEW 比较、类别聚合与证据回写。查询与源参考分别形成键和值；通道度量参与空间相似度，类别相对优势调节传输。比较路径保留原传输，值路径采用边际外积聚合。行边际 ρ_{si} 对应查询槽位，列边际 κ_{sj} 对应参考槽位；外积还须除以有效总质量 M_s。图中 64 维描述包含逐层投影，末端类别证据经空间分配和 1×1 映射后回写骨干。

4.4.2 类别条件的参考聚合

记 T_s 的有效行、列边际为 $\rho_{si} = \sum_j T_{sij}$、$\kappa_{sj} = \sum_i T_{sij}$，有效总质量为 $M_s = \sum_i \rho_{si}$。选用的聚合版在值传递阶段使用

$$T_{sij}^{\mathrm{agg}} = \frac{\rho_{si} \kappa_{sj}}{M_s}, \qquad \bar{v}_s = \frac{\sum_j \kappa_{sj} v_{sj}^{\mathrm{ref}}}{M_s}. \tag{11}$$

上述等式适用于分母非零的位置，其余位置屏蔽。$\bar{v}_s$ 实际是按列边际汇总的区域参考值，不再保留查询槽位到参考槽位的一一精细搬运。参考权重仍依赖原传输与相似度：先计算 $g_{si} = \sum_j T_{sij} S_{sij} / \rho_{si}$，再在合法参考间令 $\beta_{si} = \mathrm{softmax}_s(g_{si}/0.1)$。类参考表示为

$$P_{ic} = \frac{\sum_{s:y_s=c} \beta_{si} \bar{v}_s}{\sum_{s:y_s=c} \beta_{si}}. \tag{12}$$

边际聚合保留查询相关的参考选择及类内组织，将局部值对应压缩为区域参考摘要。

4.4.3 类别证据场及空间回写

查询值与各类参考表示的距离形成候选类别证据，取 $e_{ic} = -D_{ic}/0.1$，并在可用类别中中心化：

$$
\begin{aligned}
D_{ic} &= \sum_{d} w_{c,d}(v_{i,d}^{q} - P_{ic,d})^{2}, \\
\tilde{e}_{ic} &= e_{ic} - \frac{1}{|\mathcal{C}_i|} \sum_{c' \in \mathcal{C}_i} e_{ic'}.
\end{aligned}
\tag{13}
$$

屏蔽不可用类别后，以局部槽位的空间占比 $\eta_i(u)$ 将证据落回 layer3 网格：

$$
\begin{aligned}
E_c(u) &= \sum_{i} \eta_i(u)\tilde{e}_{ic}, \\
F_3^{+}(u) &= F_3(u) + 0.1 W_p^{\text{out}} E(u).
\end{aligned}
\tag{14}
$$

W_p^{out} 为 K 个类别证据通道到 1024 个骨干通道的 1×1 卷积。layer4 继续加工 F_3^{+}，深层 RGRP 从该特征读取区域摘要。RCEW 将参考提供的类间关系引入特征流，补充 CRFB 的单图调节和 RGRP 的区域汇总。

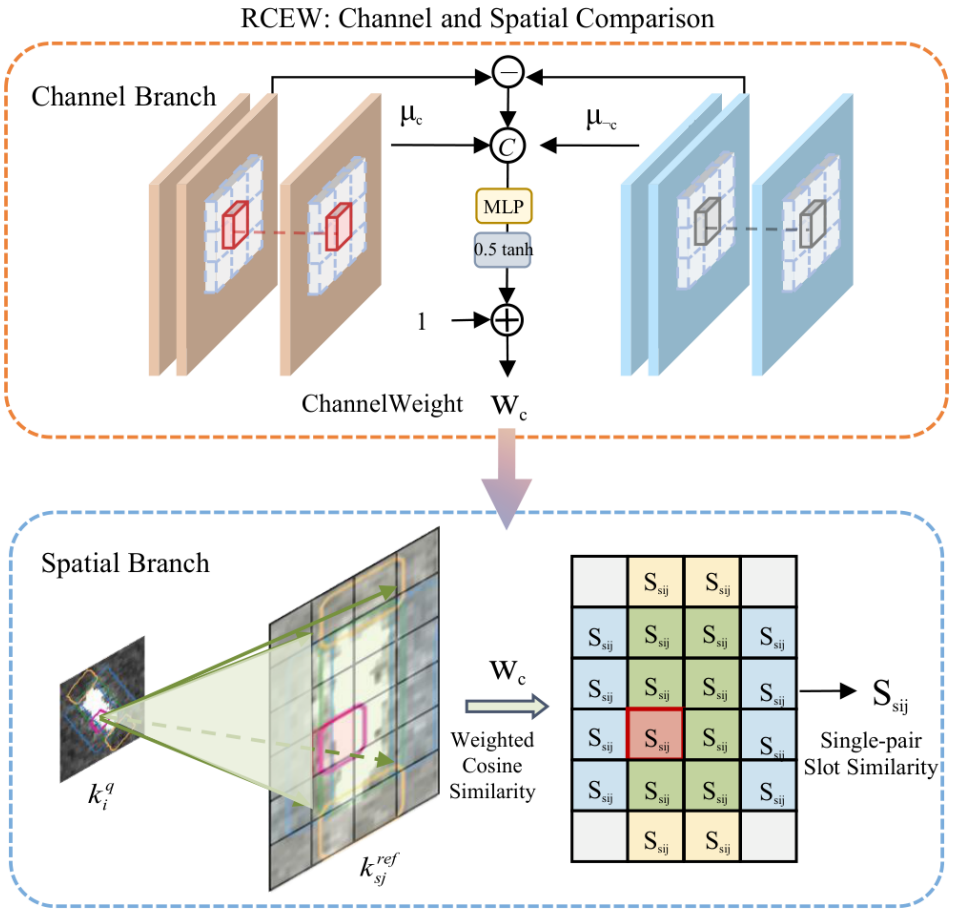


图 7 RCEW 的通道与空间比较分支。类内 / 类外参考统计生成正通道度量 w_c，同时作用于局部键相似度 S_{sij} 和值距离 D_{ic}；空间分支由相似度形成类别相对优势。

最后的区域读出优化固定参考路径，式（14）实现为 $F_3^{+} = F_3^{\text{live}} + \Delta F_3^{\text{anchor}}$，其中锚点残差由已训练的 RCEW 产生。

4.5 多层融合与最终分类

对极化 p 和区域 r，令 $t_{p,r}^{(2)} = \mathrm{Pool}_r(F_{2,p})$、$t_{p,r}^{(3)} = \mathrm{Pool}_r(F_{3,p}^{+})$，最终区域描述为

$$R_{p,r} = t_{p,r}^{(2)} + D_p t_{p,r}^{(3)} + \delta_{p,r}^{(2)}. \tag{15}$$

深层线性投影 D_p 将 1024 维映射为 512 维，使相同区域的浅层、深层和引导补充项可以相加；不同区域之间保持拼接。layer4 得到有效范围全局平均描述 $g_p \in \mathbb{R}^{2048}$，每极化表示为 $h_p = [g_p; R_{p,\mathrm{body}}; R_{p,\mathrm{end}}; R_{p,\mathrm{side}}] \in \mathbb{R}^{3584}$。将可用极化描述及标记拼接为 $h = [a_{VV}h_{VV}; a_{VH}h_{VH}; a_{VV}; a_{VH}]$，得到分类分数：

$$z = W_{\mathrm{head}} h + b_{\mathrm{head}}. \tag{16}$$

$a_p \in \{0, 1\}$ 为极化可用性，分类输入共 7170 维。最终 softmax 输出 K 类概率。

4.6 分阶段优化及干预指导约束

网络采用分阶段优化。首先从 ImageNet 预训练权重出发，在源训练子集上更新 RGRP、分类头及 layer3 末块的三层卷积，建立区域证据表征；随后在另一源子集上执行干预指导适配，仅更新上述三层卷积。合并两个源子集后，依次训练 RCEW 及分类头、CRFB 及相邻 conv3 和分类头、响应引导区域补充及分类头。CRFB 阶段以 0.02 权重加入类别响应辅助交叉熵。所有阶段仅使用源标签，未参与当前阶段优化的部分保持固定。

源样本权重按类别内独立船数和同船观测次数修正，参考训练及其后阶段对阶段起点分差小于 1 的源难例乘 2。区域补充阶段训练 180 步，batch 为 24；输出映射、值投影、分类头的基础学习率分别为 $10^{-3}, 3\times10^{-4}, 10^{-5}$。各阶段使用 AdamW，权重衰减 0.01、梯度裁剪阈值 5，BN 统计不更新。完整模型比较从共同预训练起点重复全部阶段；算子机制实验则固定同一上游，仅重复待比较阶段，两类结果分别报告。

训练框架还包含干预指导约束。对源样本，以式（1）固定竞争类，要求结构操作同时降低交叉熵、提高竞争类分差，并优于匹配均值控制，三个初筛阈值均为 0.01。随后复核正确类概率与 $m_{\max}$ 均提高，将通过样本标记为 $u_n = 1$。筛选直接使用干预图的教师预测。

所有原图均接受交叉熵监督；教师原本正确的样本额外接受分布保持约束；$u_n = 1$ 的样本进一步接受原图教师判别优势下界保护。以 n 表示训练样本，$z_n^0 = T(x_n^0)$、z_n^S 分别为原图教师与学生分数，$b_{nc} = \mathrm{stopgrad}(z_{n,y_n}^0 - z_{nc}^0)$，则

$$\begin{aligned} \ell_{\mathrm{guide},n} &= \frac{1}{K-1}\sum_{c\neq y_n}[b_{nc} - (z_{n,y_n}^S - z_{nc}^S)]_+^2, \\ \mathcal{L}_{\mathrm{guide},w} &= \frac{\sum_n w_n u_n \ell_{\mathrm{guide},n}}{\sum_n w_n}. \end{aligned} \tag{17}$$

$$\mathcal{L}_{\mathrm{adapt}} = \mathcal{L}_{\mathrm{CE},w} + 0.1\mathcal{L}_{\mathrm{KL,correct},w} + \lambda\mathcal{L}_{\mathrm{guide},w}. \tag{18}$$

教师量均停止梯度。该约束保护原图教师分差，预测时输入原始 SAR 图像，不执行依赖真实类别的干预筛选。完整模型及配套对照均由各自的源端教师生成筛选标记，并采用相同的适配规则。

5 实验设置

5.1 数据集介绍

本文使用 OpenSARShip 1.0（OSS1）、OpenSARShip 2.0（OSS2）和自建 24 港数据集。表 3 汇总实际整理的数据规模；公开数据数量按本研究解析清单统计。每条观测对应一个船舶目标，VV/VH

为其两种极化视图。

表 **3** 数据集组成。

数据集	观测规模	类别与采集
OSS1	3,030 条 GRDH 记录；兼容子集 1,349 条、1,110 艘船	分类取 4 类；源 527、开发 89、评价 63 条
OSS2	9,120 条记录：6,780 条 GRDH、2,340 条 SLC	本文分类取 4 类 GRDH；源 719、开发 228、评价 378 条
自建 24 港	38,091 条观测；18,766 个非空 MMSI	8 类、24 港、841 个 IW-GRDH 产品

公开数据集。 OSS1 与 OSS2 沿用原生船舶裁片及元数据。细粒度标签仅保留与任务类别一致的记录，笼统 Cargo 和 Tanker 标签不直接映射为普通货船或原油轮。OSS1 八类兼容子集以散货船为主（816 / 1,349），用于输入干预及联合读出分析；两个公开集的分类比较均采用散货船、普通货船、化学品 / 成品油轮和集装箱船四类 GRDH 图像，以保证各类参考与输入覆盖。

公开集各极化分别执行固定 OBB 定位，检测置信度达到 0.25 且几何有效时进入对应分支。在 OSS2 源、开发和评价集合中，分别有 48、22 和 30 条观测仅一个极化满足条件；这些观测的另一极化原始文件仍存在。模型通过式（16）的可用性标记处理该情况，符合检测后分类中某一极化定位不成功、另一极化仍可用于识别的输入条件。

自建 **24** 港数据集。数据来源为 Sentinel-1A 和 Sentinel-1C 的 IW-GRDH 双极化产品，依据 AIS 关联的船舶身份与类型组织八类目标，保存 VV/VH 图像、源产品号、港口、裁片位置及目标几何信息。采集时间为 2025 年 1 月 1 日至 2026 年 2 月 24 日；38,091 条观测中，32,184 条来自 Sentinel-1A，5,907 条来自 Sentinel-1C。841 个产品按平台与绝对轨道合并为 720 个过境组，避免将同次过境的不同产品切片视为独立观测条件。本文使用地理处理后的 8 位动态裁片，不将其视为原始复数 SAR。模型输入遵循第 4.1 节的原生像素裁剪 / 补零规则；可恢复的 10 m 像素间距不等同于传感器空间分辨率。

表 4 列出 24 港的观测规模与诊断覆盖。各港含 64 至 5,756 条观测，实际覆盖 3 至 8 类；类别分布差异较大，因此同时采用 OA、BA 及逐类分析。198 条记录缺失 MMSI，同船分析仅使用可核查的非空身份。

表 **4** 自建 **24** 港逐港组成及诊断覆盖。

港口	总库观测	实际类别数	诊断观测
Antwerp-Bruges	886	3	0
Busan	871	3	48
Callao	476	8	14
Fujairah	1,158	3	178
Hamburg	1,619	3	0
Houston	804	8	9
Jebel Ali	4,602	8	1,046
Los Angeles	583	8	158
Melbourne	64	3	0
Mombasa	149	7	12
New York	470	8	0
Newcastle	299	7	25
Ningbo-Zhoushan	5,756	3	292
Port Hedland	859	6	53
Port Klang	3,425	8	1,238
Port Said	1,895	8	150
Qingdao	1,981	3	0
Richards Bay	744	8	241
Rotterdam	573	3	36

港口	总库观测	实际类别数	诊断观测
Santos	1,658	8	325
Shanghai	2,390	3	0
Singapore	5,259	8	821
Sydney Botany	304	8	10
Tanger Med	1,266	8	88
合计	38,091	合计 8 类	4,744

表 5 给出八类组成。诊断队列包含 4,744 条观测、2,973 艘船和 18 港；同船最大日期跨度配对子集包含 910 艘船、1,820 条观测，覆盖 13 港和 7 类。受控干预队列按第 3.3 节的条件另行组织。

表 **5** 自建数据集类别分布。

船型	总库观测	诊断观测
散货船	11,128	1,290
渔船	8,599	145
普通货船	5,929	439
化学品 / 成品油轮	5,827	1,480
集装箱船	2,208	519
原油轮	1,757	405
拖轮 / 拖带船	1,478	202
海工补给船	1,165	264
合计	38,091	4,744

5.2 跨场景划分与参考设置

根据产品元数据恢复平台与绝对轨道，合并同次过境的相邻产品切片，再划分源训练、开发与评价集合。训练和评价同时隔离船舶身份及过境组，查询不使用目标标签。该协议以未见船舶和未见过境组织跨场景测试，地理水域随实际产品覆盖变化，不要求训练与评价来自完全不同的港口。自建 24 港的场景描述同时保留港口归属，以分析同港和异港条件下的观测差异。表 6 给出 OSS2 类别组成。

表 **6 OSS2** 四分类划分。括号内为独立船数。

集合	散货船	普通货船	化学品/成品油轮	集装箱船	总观测/船数/过境
源训练	221（216）	73（71）	141（137）	284（259）	719 / 683 / 13
开发	87（84）	23（22）	29（29）	89（88）	228 / 223 / 4
扩围评价	132（128）	26（26）	83（81）	137（134）	378 / 369 / 5

OSS2 源数据进一步分为 478 条表征训练观测和 241 条干预适配观测。OSS1 相应使用 405 条和 122 条，合计 527 条、502 艘船、13 个过境；开发集为 89 条、87 艘船、3 个过境，评价集为 63 条不同船舶、1 个过境。OSS1 源数据的四类数量依次为 359、41、44 和 83，评价集为 15、7、10 和 31。两个公开集的源、开发与评价集合均隔离船舶身份和过境组；每个任务固定 32 个源参考，每类 8 个，参考来自表征训练子集。OSS1 评价覆盖单个过境，反映该目标场景的结果，OSS2 则覆盖五个评价过境。

5.3 评价与对照原则

OA 为总体正确率，BA 为纳入类别的召回率平均；四分类评价覆盖全部四类。同时报告 NLL、纠错与误伤事件及极化 / 区域贡献。重复训练给出均值与样本标准差，同一观测在不同种子中的翻转分别计为事件，独立船舶数量另行统计。

完整模型与普通骨干、匹配位置的 SE[15] 对照从同一 ImageNet 起点训练，均使用双极化输入、相同源划分和训练策略。SE 以压缩比 16 插入 layer2 与 layer3 末块的残差相加前。表征学习、干预适配和参考训练分别为 8、6 和 4 轮，类别反馈与区域补充各 180 步；移除组件时保留相应阶段的分类头训练。除各模块外，骨干可更新范围为 layer3 末块的三层卷积及 layer2 末块的 conv3，其余卷积固定。

完整模型、普通骨干和 SE 分别在 OSS2 开发集上比较基础学习率倍率 1.0 和 0.3，以 BA、OA、NLL 依次选择，完整模型与普通骨干选择 1.0，SE 选择 0.3。删除组件的模型继承完整模型倍率，OSS1 沿用已确定设置。完整训练使用种子 17、29 和 43。配对区间按船舶重采样，保留同船各观测及种子的对应关系。

算子机制实验固定上游表征，比较区域读出、参考消息形式及末阶段优化；同权重替换仅改变取证或回写关系，定位当前预测所依赖的证据。这些结果用于解释模块作用，与共同起点的完整训练结果分开分析。

6 结果与分析

6.1 公开数据集的完整模型比较

表 7 比较共同起点和相同训练策略下的完整模型、普通骨干及匹配位置 SE。各数据集分别使用自身源数据训练，参考库仅由源样本组成。

表 **7** 公开数据集四分类结果，三次完整训练的均值与标准差。

数据集	方法	OA（%）	BA（%）
OSS1	普通骨干	50.794 ± 4.200	46.752 ± 4.127
OSS1	匹配位置 SE	**64.550 ± 2.425**	**60.154 ± 0.642**
OSS1	本文完整模型	60.847 ± 3.304	51.737 ± 2.800
OSS2	普通骨干	55.908 ± 1.332	52.176 ± 1.506
OSS2	匹配位置 SE	54.233 ± 0.954	53.497 ± 1.802
OSS2	本文完整模型	**61.023 ± 2.610**	**55.630 ± 3.498**

完整模型相对普通骨干在 OSS1 和 OSS2 上的平均 OA 分别提高 10.053 和 5.115 个百分点，BA 提高 4.985 和 3.454 个百分点。OSS2 相对普通骨干和 SE 的 OA 增量船级 95% 区间分别为 [1.422,8.642] 和 [2.814,10.908] 个百分点，BA 增量区间包含零。区间采用类别分层的配对船级 bootstrap，共 3000 次；其刻画当前评价船舶上的抽样不确定性。

OSS1 中，完整模型相对普通骨干的 OA 与 BA 在三个种子中均提高，其中散货船召回达到 71.11%；SE 取得该队列最高的总体 OA 与 BA。结合 OSS2 结果，证据组织的收益体现在不同目标场景中的类别识别改善，而非对所有注意机制和类别的一致优势。

6.2 完整训练的组件消融

表 8 在 OSS2 中分别移除一个组件，保留其余结构、共同起点和训练阶段，并重新训练。删除 RGRP 同时取消相应区域读出及引导接口，删除 CRFB 或 RCEW 则移除对应反馈或参考路径。

表 **8 OSS2** 完整训练消融，三种子均值与标准差。

配置	OA（%）	BA（%）
无 CRFB	60.670 ± 1.305	**56.554 ± 1.239**
无 RGRP	56.261 ± 0.666	52.164 ± 0.744
无 RCEW	**61.023 ± 0.929**	56.477 ± 0.991
完整模型	**61.023 ± 2.610**	55.630 ± 3.498

RGRP 的贡献最明确：完整模型相对无 RGRP 的 OA/BA 提高 4.762/3.466 个百分点，三个种子均为正，OA 船级 95% 区间为 [1.046,8.444] 个百分点。化学品 / 成品油轮和集装箱船召回分别提高 6.827 和 6.569 个百分点，表明区域取证有效补充了这两类的判别信息。

CRFB 和 RCEW 的完整重训增量较小，二者的作用进一步通过对应关系替换及消息形式比较分析。对同一完整模型开启 RCEW，OSS2 平均 OA 变化为 +1.235 个百分点、BA 为 −0.136 个百分点，合计 40 次纠错和 26 次误伤；OSS1 为 +1.587/+1.371 个百分点，预测翻转集中于一个种子。路径贡献与删除后重训的差别表明，需要结合具体证据利用过程解释组件效用。

6.3 响应引导区域池化

保持上游、参考库和样本流一致，比较区域均值补充、从局部内容新学习注意的补充、以及复用 CRFB 类别响应的补充。均值对照重复四份均值摘要以匹配接口，内容注意另有 4096 个评分参数；其有效表达能力和初始化来源仍有差别，比较首先检验已有类别响应是否值得复用。

表 **9 OSS2** 评价集上的区域读出比较，固定上游、三次末阶段训练。

读出方式	OA（%）	BA（%）	NLL
增加补充读出前的固定上游	62.434	59.718	1.14782
区域均值补充	61.464 ± 0.305	58.233 ± 0.710	1.14277
普通内容注意补充	61.464 ± 0.666	58.050 ± 0.674	1.14460
CRFB 响应引导 RGRP 补充	**62.346 ± 0.153**	**59.781 ± 0.220**	**1.14005**

响应引导相对均值补充的 OA/BA 分别提高 0.882/1.548 个百分点，三个种子均为正；相对内容注意提高 0.882/1.731 个百分点。相对固定上游则为 −0.088/+0.063 个百分点，表明类别响应在新增区域读出中更有效地保留了原有判别能力。开发集三个方案的平均 OA/BA 均为 62.281%/55.731%。

6.4 正确空间对应是否参与判断

在响应引导模型权重固定时，将区域内部权重改成均匀值，或反向置换非空位置的权重。均匀替换保持归一化总量但改变权重分布；位置置换同时保持总量与直方图，仅改变权重与局部特征的对应。

表 **10** 同权重取证方式替换，**OSS2** 评价 **378** 条。

取证方式	OA（%）	BA（%）
正确响应位置	62.346	59.781
区域内均匀权重	61.464	57.753
区域内位置置换	60.758	57.297
关闭新增读出	62.169	58.796

正确响应相对位置置换平均提高 OA 1.587、BA 2.484 个百分点，表明该评价队列中的正确权重—特征对应实际参与分类。响应引导相对配套均值模型共有 10 次纠错、0 次误伤，涉及 7 条观测、7 艘船和 3 个过境；其中 9 次在增加读出前已正确，所以主要作用是减少不合适读出适配造成的损失。

图 8 中普通货船 000133 的真实类分差，在均值读出下为 −0.06155，响应引导下为 +0.22820；同权重均匀替换和位置置换后分别为 −0.06187 与 −0.13565。该样本关闭新增读出时仍正确，说明优势来自更合适的区域取证。线性分解中，VV 框内、轴端与侧向对普通货船相对油轮的优势贡献分别约 +0.0860、+0.0449 和 +0.1778，VH 三项为负，体现了极化及区域作用的差异。

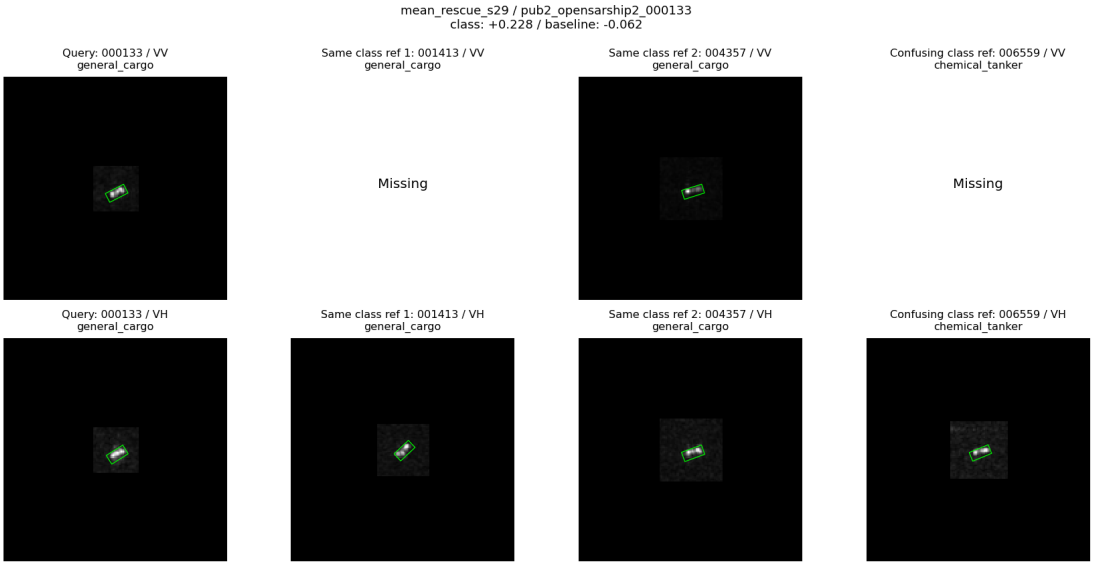


图 8 普通货船 000133 及合法参考的 VV/VH 图像。baseline 为均值读出对照；Missing 表示该极化未通过输入有效性筛选。图像按原生尺度裁剪或补零。

6.5 参考证据的消息形式

在固定前端的独立 RCEW 实验中，三组配对训练使用相同源数据、查询 / 参考 episode 和 120 步预算，仅更新相应参考模块及分类头。表 11 采用相同训练长度下的末轮结果。

表 **11 RCEW** 独立训练的开发集比较，固定前端、三种子平均。

方案	OA（%）	BA（%）
无 RCEW，更新分类头	58.626 ± 0.253	50.017 ± 0.162
普通参考特征回写	58.772 ± 0.439	50.119 ± 0.281
类别证据回写，精细对应	60.234 ± 1.410	51.830 ± 0.852
类别证据回写，保留边际聚合	**61.257 ± 2.251**	**53.511 ± 2.442**

聚合证据回写相对无 RCEW 提高 OA/BA 2.632/3.495 个百分点，相对普通参考特征回写提高 2.485/3.392 个百分点。普通参考特征回写仍保留类别、区域和极化组织，因此这一比较不只是 “有类别信息” 对 “完全无组织信息”。图 9 的集装箱船 000867 在三个种子中均被类别证据回写判对，而普通参考回写、无 RCEW 和其自身关闭回写均错。seed17 的真实类分差由无 RCEW 的 −0.334、参考特征回写的 −0.286 变为 +0.275，构成直接路径案例。

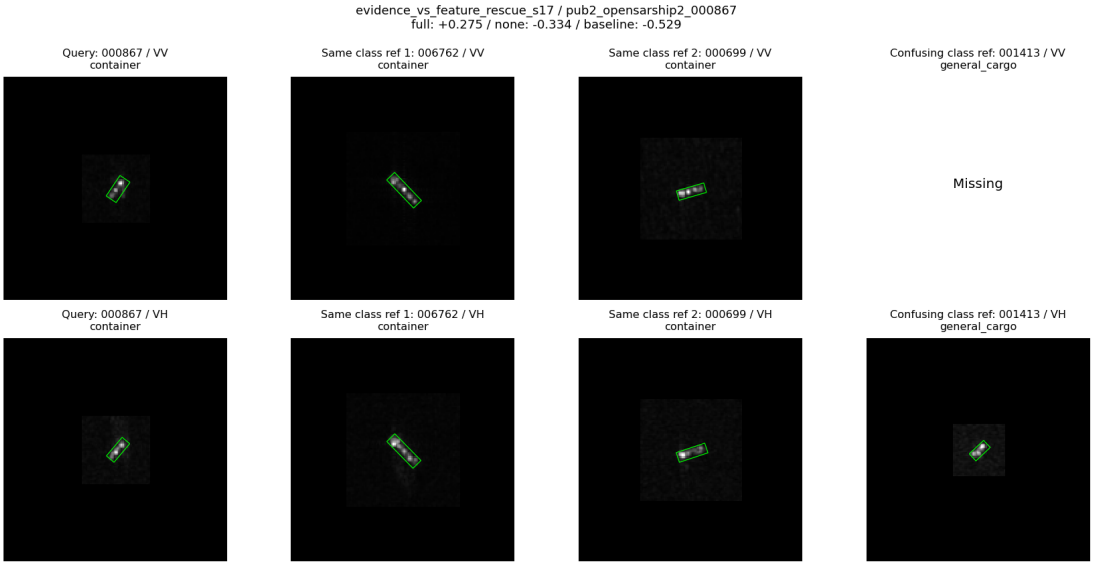


图 9 集装箱船 000867 及同类、混淆类参考。full 为类别证据回写，none 为关闭参考模块，baseline 为图示原始基线。样本在三次训练中均由类别证据回写判对。

对精细对应模型保持权重并改用边际聚合，三个种子、228 条查询的预测均不变；配套训练的聚合版平均表现更好。保留类别关系与参考选择后，区域聚合已能提供有效的回写消息。

6.6 固定上游下的参考与读出协同

固定相同上游，移除 RCEW 残差后重新计算 layer4 与深层区域摘要，再以相同初始化、源样本顺序和 180 步预算训练区域补充及分类头。保留 RCEW 的组合沿用表 9 结果。此对照比较固定上游条件下、有无参考证据时的配套末阶段优化，不等同于表 8 的共同起点完整重训。

表 **12** 固定上游下有无 **RCEW** 的末阶段配套训练比较。

队列	配置	OA（%）	BA（%）	NLL
开发 228	无 RCEW 配套训练	61.404 ± 0.439	54.581 ± 0.287	1.23567
开发 228	保留 RCEW	62.281 ± 0.439	55.731 ± 0.284	1.23337
评价 378	无 RCEW 配套训练	61.993 ± 0.808	59.020 ± 0.951	1.14967
评价 378	保留 RCEW	62.346 ± 0.153	59.781 ± 0.220	1.14005

RCEW 在开发与评价队列上的平均 OA/BA 增量分别为 +0.877/+1.149 和 +0.353/+0.760 个百分点。评价集三个种子的 NLL 均下降，平均降低 0.00963，说明在该固定上游和配套读出设置下，参考证据能提供小幅净收益。

评价集三次训练合计 13 次纠错与 9 次误伤，涉及 8 艘与 6 艘船。集装箱船 002950 在 seed17 下的真实类分差由无 RCEW 配套模型的 −0.07493 提高至 +0.36983，同权重关闭回写亦会误判。这一案例将参考证据的作用落实为正确类相对竞争类的优势恢复。

6.7 计算成本与推理加速

计算成本在 RTX 5050 Laptop GPU（8 GB）上测量，采用 FP32、关闭 TF32，输入为双极化 160×160 chip。计时覆盖 GPU 上的图像及掩膜到分类分数的完整前向，不含检测、文件读取和 CPU 预处理。完整模型缓存 32 个源参考的描述子；单张延迟经预热后进行三组、每组 15 次测量，取中位数。

表 **13** 四分类模型的在线计算成本。运算量仅统计卷积与矩阵乘，一次乘加计两次操作。

方法	参数（M）	运算量（G）	延迟（ms）	显存（MiB）
普通骨干	23.524	8.342	6.51	158.7
匹配位置 SE	23.690	8.343	7.50	161.5
本文完整模型	25.053	8.673	129.47	174.0

参数量统计实际执行的网络参数，显存为 PyTorch 在线分配峰值。完整模型增加 6.50% 的执行参数和 3.96% 的卷积 / 矩阵乘运算量；后者未覆盖归一化及传输迭代等操作。同权重关闭 RCEW 后延迟降至 19.06 ms，说明参考路径是主要耗时来源。参考缓存占 3.755 MiB，一次构建耗时 43.43 ms。

进一步将 RCEW 固定形状的 60 步传输迭代捕获为 CUDA Graph，保持权重、FP32 精度及 32 个参考不变。独立配对计时中，完整前向的单张中位延迟由 134.17 降至 49.37 ms，加速 2.72 倍；批量 8 的整批延迟由 138.70 降至 63.87 ms，吞吐达 125.3 张/s。OSS2 同一种子的 378 条预测类别全部保持一致。该稳态加速不含一次性图捕获开销，且仅比较同一完整模型优化前后的执行效率。

7 讨论

公开集比较与机制实验形成了相互补充的证据链：完整训练检验证据组织的整体效用，区域消融定位主要收益来源，权重置换检验类别响应与位置对应的必要性，参考案例展示竞争类别优势如何被修正。三类模块分别承担特征反馈、区域汇总和跨样本比较，局部机制贡献与完整训练增量不作简单相加。

参考规模、类内观测覆盖及前端表征共同影响回写效用，外围响应的物理来源可结合更精细标注继续研究。干预选样为训练提供样本级判别保护，公平比较中的各方法采用相同规则。不同港口、时相与成像条件构成联合场景变化，本文以可追溯的局部证据处理提升分类能力，不要求将所有变化压缩为单一不变表征。

8 结论

本文从同船跨场景变化和受控图像干预出发，发现局部响应的判别作用依赖极化、区域及类别竞争，并据此构建 CRFB、RGRP 与 RCEW 三类证据处理模块。共享骨干上的专属极化处理保留响应差异，类别响应指导区域取证，源参考比较形成可回写的类别证据场。两个公开集上的完整训练均优于普通骨干，OSS2 消融显示 RGRP 具有明确的净收益；内部替换与原图案例进一步解释了类别响应和参考回写的条件性作用。通过将跨场景分类问题落实到证据来源、区域组织及类别竞争，本文提供了可追溯的模型设计与实验路径。

参考文献

[1] L. Huang, B. Liu, B. Li, W. Guo, W. Yu, Z. Zhang, and W. Yu. OpenSARShip: A Dataset Dedicated to Sentinel-1 Ship Interpretation. *IEEE JSTARS*, 11(1):195–208, 2018. doi:10.1109/JSTARS.2017.2755672.

[2] H. Xie, J. He, Z. Lu, and J. Hu. Two-Level Feature-Fusion Ship Recognition Strategy Combining HOG Features with Dual-Polarized Data in SAR Images. *Remote Sensing*, 15(18):4393, 2023. doi:10.3390/rs15184393.

[3] Z. Shao, T. Zhang, and X. Ke. A Dual-Polarization Information-Guided Network for SAR Ship Classification. *Remote Sensing*, 15(8):2138, 2023. doi:10.3390/rs15082138.

[4] J. He et al. CPINet: Towards A Novel Cross-Polarimetric Interaction Network for Dual-Polarized SAR Ship Classification. *Remote Sensing*, 16(18):3479, 2024. doi:10.3390/rs16183479.

[5] N. Xie, T. Zhang, W. Guo, Z. Zhang, and W. Yu. Dual Branch Deep Network for Ship Classification of Dual-Polarized SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–15, 2024. doi:10.1109/TGRS.2024.3372021.

[6] Z. Liu, K. Li, L. Wang, and Z. Zhang. Multi-Scale Alignment Domain Adaptation for Ship Classification in Multi-Resolution SAR Images. *IEEE Transactions on Automation Science and Engineering*, 22:4051–4062, 2025. doi:10.1109/TASE.2024.3407130.

[7] L. Chen, J. Li, H. Zhong, H. Shi, Z. Yang, and W. Li. PGMNet: A Prototype-Guided Multimodal Network for Ship Recognition in SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 63:5215517, 2025. doi:10.1109/TGRS.2025.3583282.

[8] R. C. Fong and A. Vedaldi. Interpretable Explanations of Black Boxes by Meaningful Perturbation. *ICCV*, 3449–3457, 2017. doi:10.1109/ICCV.2017.371.

[9] S. Hooker, D. Erhan, P.-J. Kindermans, and B. Kim. A Benchmark for Interpretability Methods in Deep Neural Networks. *NeurIPS*, 32, 2019.

[10] X. Hou, W. Ao, Q. Song, J. Lai, H. Wang, and F. Xu. FUSAR-Ship: Building a High-Resolution SAR-AIS Matchup Dataset of Gaofen-3 for Ship Detection and Recognition. *Science China Information Sciences*, 63:140303, 2020. doi:10.1007/s11432-019-2772-5.

[11] S. Zhao and H. Lang. Improving Deep Subdomain Adaptation by Dual-Branch Network Embedding Attention Module for SAR Ship Classification. *IEEE JSTARS*, 15:8038–8048, 2022. doi:10.1109/JSTARS.2022.3206753.

[12] Y. Shi, L. Du, Y. Guo, Y. Du, and Y. Li. Unsupervised Domain Adaptation for Ship Classification via Progressive Feature Alignment: From Optical to SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–17, 2024. doi:10.1109/TGRS.2024.3458937.

[13] Y. Qi, L. Wang, C. Zhao, P. T. Mathiopoulos, T. Ohtsuki, and F. Adachi. SCRC-Net: A Structure-Constrained and Representation-Consistent Network for SAR Ship Classification. *Pattern Recognition*, 180:114294, 2026. doi:10.1016/j.patcog.2026.114294.

[14] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, "Learning Deep Features for Discriminative Localization," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 2921-2929, doi: 10.1109/CVPR.2016.319.

[15] J. Hu, L. Shen, and G. Sun, "Squeeze-and-Excitation Networks," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 7132-7141, doi: 10.1109/CVPR.2018.00745.

[16] H. Lee, H.-E. Kim, and H. Nam, "SRM: A Style-Based Recalibration Module for Convolutional Neural Networks," in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 1854-1862, doi: 10.1109/ICCV.2019.00194.

[17] Z. Gao, J. Xie, Q. Wang, and P. Li, "Global Second-Order Pooling Convolutional Networks," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 3024-3033, doi: 10.1109/CVPR.2019.00314.

[18] Y. Chen, Y. Kalantidis, J. Li, S. Yan, and J. Feng, "A^2-Nets: Double Attention Networks," in Advances in Neural Information Processing Systems, vol. 31, 2018, pp. 352-361.

[19] Y. Cao, J. Xu, S. Lin, F. Wei, and H. Hu, "GCNet: Non-Local Networks Meet Squeeze-Excitation Networks and Beyond," in Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), 2019, pp. 1971-1980, doi: 10.1109/ICCVW.2019.00246.

[20] J. Dai, Y. Li, K. He, and J. Sun, "R-FCN: Object Detection via Region-based Fully Convolutional Networks," in Advances in Neural Information Processing Systems, vol. 29, 2016, pp. 379-387.

[21] X. Li, X. Wang, R. Zhu, Z. Ma, J. Cao, and J.-H. Xue. Selectively Augmented Attention Network for Few-Shot Image Classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(2):1180–1192, 2025. doi:10.1109/TCSVT.2024.3480279.

[22] J. Snell, K. Swersky, and R. Zemel, “Prototypical Networks for Few-shot Learning,” in Advances in Neural Information Processing Systems, vol. 30, 2017, pp. 4077-4087.

[23] W. Li, L. Wang, J. Xu, J. Huo, Y. Gao, and J. Luo, “Revisiting Local Descriptor Based Image-To-Class Measure for Few-Shot Learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 7260-7268, doi: 10.1109/CVPR.2019.00743.

[24] R. Hou, H. Chang, B. Ma, S. Shan, and X. Chen, “Cross Attention Network for Few-shot Classification,” in Advances in Neural Information Processing Systems, vol. 32, 2019, pp. 4003-4014.

[25] C. Zhang, Y. Cai, G. Lin, and C. Shen. DeepEMD: Few-Shot Image Classification With Differentiable Earth Mover’s Distance and Structured Classifiers. *CVPR*, 12203–12213, 2020.

[26] D. Wertheimer, L. Tang, and B. Hariharan, “Few-Shot Classification With Feature Map Reconstruction Networks,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 8012-8021, doi: 10.1109/CVPR46437.2021.00792.

[27] J. Wu, D. Chang, A. Sain, X. Li, Z. Ma, J. Cao, J. Guo, and Y.-Z. Song. Bi-Directional Ensemble Feature Reconstruction Network for Few-Shot Fine-Grained Classification. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(9):6082–6096, 2024. doi:10.1109/TPAMI.2024.3376686.

[28] W. Li, W. Yang, L. Liu, W. Zhang, and Y. Liu. Discovering and Explaining the Noncausality of Deep Learning in SAR ATR. *IEEE GRSL*, 20:1–5, 2023. doi:10.1109/LGRS.2023.3266493.

[29] D. Yin, R. G. Lopes, J. Shlens, E. D. Cubuk, and J. Gilmer. A Fourier Perspective on Model Robustness in Computer Vision. *NeurIPS*, 32, 2019.

[30] A. S. Ross, M. C. Hughes, and F. Doshi-Velez. Right for the Right Reasons: Training Differentiable Models by Constraining Their Explanations. *IJCAI*, 2017.

[31] Z. Huang, H. Wang, E. P. Xing, and D. Huang, “Self-challenging Improves Cross-Domain Generalization,” in Computer Vision - ECCV 2020, Lecture Notes in Computer Science, vol. 12347, 2020, pp. 124-140, doi: 10.1007/978-3-030-58536-5_8.

[32] A. S. Ross and F. Doshi-Velez, “Improving the Adversarial Robustness and Interpretability of Deep Neural Networks by Regularizing Their Input Gradients,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 32, no. 1, 2018, pp. 1660-1669, doi: 10.1609/aaai.v32i1.11504.

[33] P. Chattopadhyay, K. Sarangmath, V. Vijaykumar, and J. Hoffman. PASTA: Proportional Amplitude Spectrum Training Augmentation for Syn-to-Real Domain Generalization. *ICCV*, 19288–19300, 2023.

[34] H. Cheng, S. Yang, J. T. Zhou, L. Guo, and B. Wen. Frequency Guidance Matters in Few-Shot Learning. *ICCV*, 11814–11824, 2023.

[35] Y. Wang, F. Liu, Z. Chen, Y.-C. Wu, J. Hao, G. Chen, and P.-A. Heng. Contrastive-ACE: Domain Generalization Through Alignment of Causal Mechanisms. *IEEE Transactions on Image Processing*, 32:235–250, 2023. doi:10.1109/TIP.2022.3227457.

[36] K. He, X. Zhang, S. Ren, and J. Sun. Deep Residual Learning for Image Recognition. *CVPR*, 770–778, 2016.