受控干预启发的极化与区域证据学习用于跨场景 SAR 船舶分类

Mo Yu, Xiangguang Leng, Member, IEEE, Qihao Huang, Jilong Li, and Kefeng Ji, Member, IEEE

1

摘要

跨场景合成孔径雷达（SAR）船舶分类不仅受到观测条件变化的影响，还面临局部判别证据利用不充分的问题。不同极化通道及目标空间区域中的响应具有不同的类别判别作用，其贡献随局部尺度及类别竞争关系而变化。针对这一问题，本文通过同船重复观测与极化、区域及尺度受控干预，分析局部响应对类别判别的影响，并提出一种受控干预启发的极化与区域证据学习网络。该网络基于共享 ResNet-50 骨干，设计类别响应反馈模块（CRFB）、响应引导区域池化模块（RGRP）和参考类别证据回写模块（RCEW），分别实现类别相关特征调节、结构化区域证据提取及跨样本类别证据引入。同时，采用受控干预选样与判别优势保护约束，将源样本的干预响应用于训练对象选择与原图判别保护。在 OpenSARShip 2.0 四分类和自建 24 港八分类跨场景评估中，分阶段完整模型相较于同协议普通骨干，三种随机种子的平均总体准确率（OA）分别提高 5.115 和 5.485 个百分点，平衡准确率（BA）分别提高 3.454 和 3.730 个百分点。OSS2 全骨干微调进一步达到 64.727% 的 OA 与 59.396% 的 BA；分阶段配套消融中，RGRP 分别带来 4.762 和 3.466 个百分点的 OA 与 BA 增益。实验结果表明，差异化组织极化与区域判别证据能够改善跨场景 SAR 船舶分类性能。

关键词： SAR 船舶分类；跨场景泛化；双极化；区域池化；参考证据；受控干预

1 引言

合成孔径雷达（Synthetic Aperture Radar，SAR）能够在不同光照和天气条件下获取海面目标信息，为海洋监测与船舶识别提供观测手段。船舶分类作为目标检测后的重要环节，依据船体外形、局部响应与空间结构识别船舶类型，服务于海上交通监测与港口管理。OpenSARShip 等数据资源推动了 Sentinel-1 船舶解译研究 [1]。然而，SAR 图像中的船舶表征不仅取决于目标自身结构，还随观测几何、极化方式和成像环境变化。同一船舶在不同场景下可能呈现明显不同的局部响应，不同船型也可能具有相似外观，使训练场景之外的识别面临困难。

本文研究包含不同采集时相、观测条件及港口水域的跨场景 SAR 船舶分类，评价模型在上述因素共同变化时的识别能力。场景由采集产品所属过境、成像条件和地理水域共同描述，涵盖同港不同采集和不同港口 / 水域中的观测变化。实验通过产品元数据确定过境组，并同时隔离船舶身份，以考察未见船舶与未见场景下的识别能力。

Sentinel-1 船舶影像同时受目标结构、成像几何、极化、海面环境与运动状态影响 [1]。除成像因素外，不同数据集采用的辐射定标、灰度转换、重采样与裁片方式也会改变模型实际接收的数值分

[1]This work was supported in part by the National Natural Science Foundation of China under Grant 62471475, in part by Hunan Provincial Natural Science Foundation of China under Grant 2024JJ4045, and in part by the Science and Technology Innovation Program of Hunan Province under Grant 2024RC3124. M. Yu, X. Leng, Q. Huang, J. Li, and K. Ji are with the College of Electronic Science and Technology, National University of Defense Technology, Changsha 410073, China. Corresponding author: Xiangguang Leng (e-mail: luckight@163.com).

布、目标尺度和邻域覆盖。表 1 概括这些因素作用于输入表征的主要途径，各数据集的具体预处理见表 5。因此，跨场景分类中的表征差异既涉及实际观测变化，也涉及数据处理方式。

表 **1** 影响 **Sentinel-1** 船舶表征的主要因素。

因素	对输入表征的影响
成像几何：入射角、相对方位	改变同一船舶的散射强度与空间分布
船舶结构：船体、甲板、上层建筑	形成目标内部的局部散射差异
极化与散射：VV/VH	同一目标在两极化中的响应不同
海洋环境：风浪、海况	改变海杂波与船海对比度
船舶运动：航速、航向	可能产生方位向偏移或散焦，并影响尾迹形态
数据集预处理：辐射定标、灰度拉伸、重采样与裁片	改变数值分布、船海对比度、局部纹理及目标 / 邻域覆盖，影响可用分类证据

图 1 展示三艘船在不同场景中的方向、强响应排列与 VV/VH 差异。其中化学品/成品油轮的两次观测来自同港、同平台，表明同港采集之间也存在显著变化。同船诊断进一步显示，原油轮较多出现一次正确、一次错误，普通货船则更多持续混淆。这些差异提示应结合类别与实际局部响应研究失效机制。

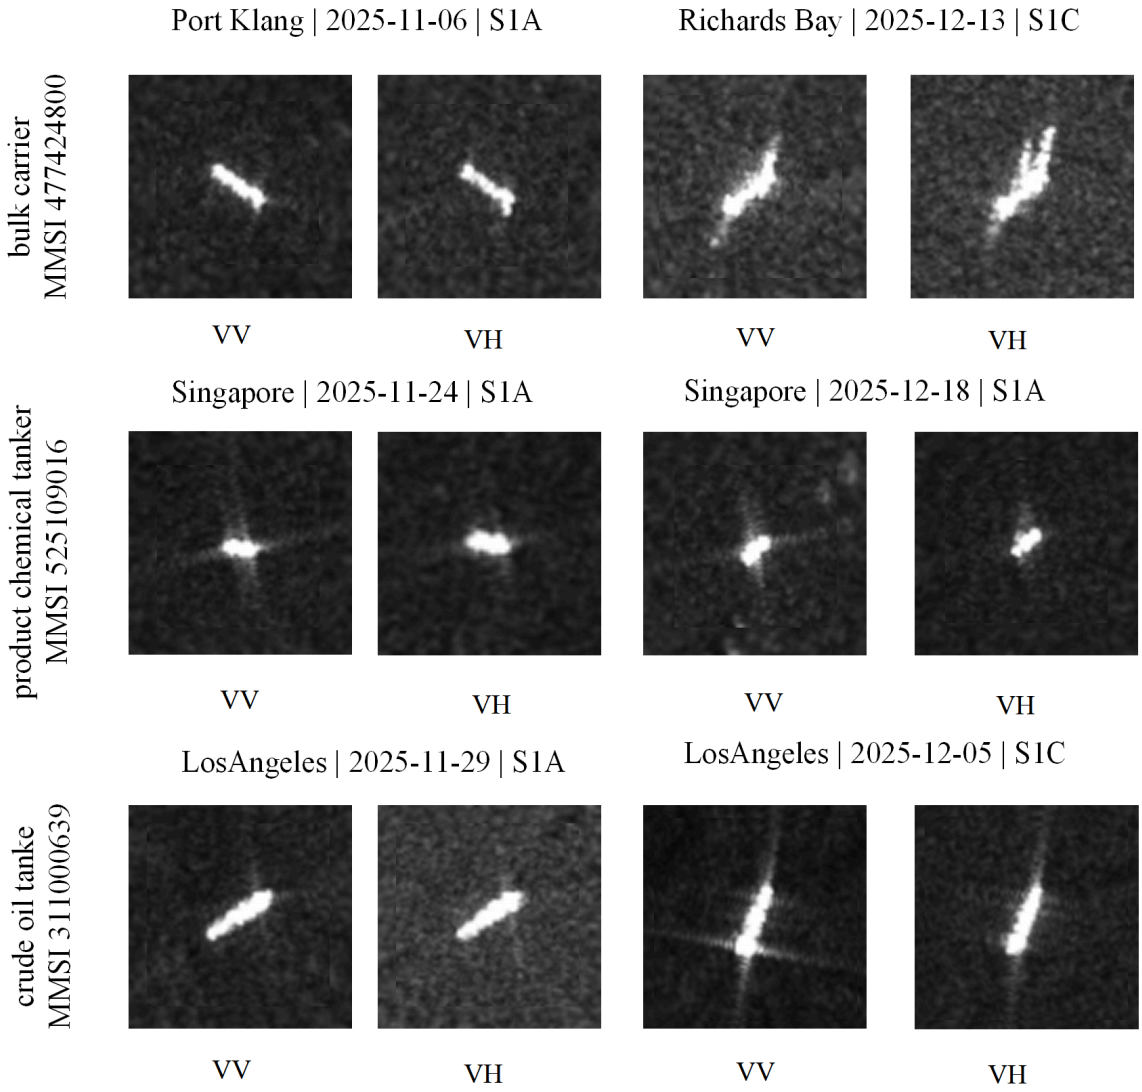


图 1 24 港数据中三艘船的配对观测。三行依次为散货船、化学品/成品油轮和原油轮；每行展示同一船舶在两次过境中的 VV/VH 图像，标注对应港口、日期、卫星平台与 MMSI。

近年来，深度学习研究从极化信息利用、目标结构表达和分布适应等方面改善 SAR 船舶分类。现

有双极化方法通过共享特征提取、多尺度融合与极化交互增强 VV 和 VH 的互补表示 [2,3,4]；结合极化与纹理的表示学习 [5]、多尺度域对齐 [6] 及目标区域引导的多模态融合 [7] 进一步拓展了可用信息。然而，完成特征融合或区域增强，并不直接回答其中哪些局部响应有助于区分当前竞争类别。本文关注不同来源的局部证据如何参与类别判别，以及其作用如何随极化、目标区域和空间尺度变化。

对于中低分辨率 SAR 图像，这一问题尤为突出。一方面，目标框内与外围并非始终具有相同的信息价值：直接裁除外围可能损失补充线索，不加区分地汇总又可能混入误导性响应。另一方面，局部响应的价值不仅取决于强弱，还取决于它所在的极化、区域及其对不同类别的影响。即使对同一类局部结构执行相同操作，正确类别和竞争类别的分数也可能以不同方向变化。因此，有必要在极化融合与空间汇总之外，显式组织局部内容与类别竞争之间的联系。

为分析这一问题，本文结合自然观测与受控输入干预开展研究。首先，通过同船重复观测考察跨场景分类变化；随后，在固定模型参数和参考条件下，分别改变输入的极化、目标相对区域及空间尺度，并设置匹配均值变化的对照，追踪正确类别与竞争类别分差。实验发现，局部操作的判别效应依赖极化和区域，并受到类别差异的调节，部分纠错来自对错误竞争类的削弱。这些发现支持按证据来源与类别关系组织信息，而非统一增强强响应或抑制外围响应。依据输入敏感性与训练后信息价值的区别 [8,9]，本文进一步通过配套训练和算子替换检验这些线索的分类效用。

基于上述发现，本文提出受控干预启发的极化与区域证据学习网络。网络采用共享 ResNet-50 骨干，并针对不同极化设置专属证据处理参数。类别响应反馈模块（Class-Response Feedback Block，CRFB）通过相对类别响应与局部内容的交叉统计生成位置相关反馈；响应引导区域池化模块（Response-Guided Regional Pooling，RGRP）保留框内、轴端和侧向的区域身份，利用类别响应指导区域内部取证；参考类别证据回写模块（Reference-Class Evidence Writeback，RCEW）将查询相对于源参考类别的比较结果转化为空间证据场，参与后续特征提取。此外，训练利用受控干预筛选源样本，并以教师分差约束保护原图上的判别优势。预测阶段使用原始 SAR 图像、目标几何及固定源参考，无需查询标签或在线干预。

本文的主要贡献如下：

1. 结合同船重复观测、区域输入对照和极化—区域—尺度受控干预，分析局部响应对正确类别与竞争类别的不同作用，为差异化组织判别证据提供实验依据。
2. 提出 CRFB、RGRP 和 RCEW，从单图类别响应反馈、结构化区域取证和跨样本类别证据回写三个层次组织信息，建立类别响应、目标几何与源参考之间的联系。
3. 构建受控干预选样与判别优势保护训练策略，并结合完整训练对比、模块消融、空间对应替换和真实船舶案例，评价整体分类效果及各类证据的利用方式。

2 相关研究

2.1 SAR 船舶分类与跨场景泛化

SAR 船舶分类需要从目标散射响应和空间结构中提取具有类别区分能力的表示。OpenSARShip 面向 Sentinel-1 船舶解译建立开放数据资源 [1]；FUSAR-Ship 基于高分三号 SAR 与 AIS 匹配支持检测和识别 [10]。不同资源在传感器、分辨率、类别体系和样本组织上存在差异，促使研究从固定分布下的识别拓展至分布适应。针对这一问题，已有研究将双分支注意与深度子域适应用于 SAR 船型分类 [11]。

MSADAN 结合尺度感知特征、多层双线性融合驱动的对抗对齐及类别对比约束，处理多分辨率 SAR 船型跨域分类 [6]。Shi 等在有标签光学源域到无标签 SAR 目标域的迁移中联合域级校准与类级对齐 [12]。这些方法分别关注分辨率变化和跨模态适配。本文从局部判别证据组织出发，关注类别不变但响应发生变化时，极化、区域及参考类别关系如何参与判断，以补充分布对齐视角，并采用船舶身份与过境组隔离的跨场景评价。

2.2 双极化、类别响应与分层证据

HOG-SiamShipCLSNet 采用共享骨干提取 VV/VH 特征，并在不同深度结合组双线性池化及 HOG 描述 [2]。DPIG-Net 使用 VV 引导 VH 与极化乘积幅度分支，通过交叉注意及残差融合组织极化信息 [3]。CPINet 结合多尺度融合、混合阶统计注意与因子化双线性编码 [4]。这些研究表明共享或专属处理、跨极化交互和高阶统计均已有方法基础。

DBDN 构造极化特征引导和纹理特征引导的两种伪 RGB 图像，进行双分支提取与融合分类 [5]。本文采用逐极化前向与共享卷积，并以极化专属类别响应连接中间特征处理和区域取证。

SCRC-Net 的结构约束融合模块从特征预测采样网格的长宽、共同旋转角与局部伸缩，以适应细长船体结构 [13]。本文利用检测 OBB 定义目标相对区域，保持框内、轴端与侧向的证据身份，再由类别响应指导区域内汇总。两者分别从采样几何和证据读出组织结构信息。

PGMNet 从 SAR 图像生成目标掩膜，以掩膜引导视觉特征对齐，并融合船舶尺寸描述的文本表征 [7]。本文 RGRP 保留船体与不同方向外围的区域身份，RCEW 引入带类别的源参考，使目标几何与跨样本判别关系分别承担区域定位和类别比较的作用。

类别响应与统计反馈方面，CAM 将线性分类权重投射到末层卷积图，生成类别相关空间响应 [14]；SENet 以全局均值生成通道权重 [15]，SRM 联合均值和标准差完成重标定 [16]，GSoP 将通道或位置二阶统计嵌入中间层反馈 [17]。本文 CRFB 保留均值支路，通过相对候选类别响应与局部值的交叉统计产生位置相关反馈，并将响应继续传递给 RGRP，用于区域内部取证。

区域上下文方面，A2-Nets 将注意汇总的全局描述按位置重新分配 [18]；GCNet 通过瓶颈变换将全局上下文反馈至特征图 [19]；R-FCN 以位置敏感得分图与 RoI 网格编码类别及相对位置 [20]。RGRP 以 OBB 框内、轴端和侧向限定证据来源，分别进行区域回写与多层读出，并复用 CRFB 响应指导浅层取证。

SAA 从原图及随机裁剪中选择查询—支持最匹配的特征，联合估计空间和通道注意后进行原型分类 [21]。本文在目标几何区域内复用候选类别响应，检验类别相关评分相对一般内容注意的取证效用。

2.3 局部参考比较与类别证据

Prototypical Networks 依据查询到类内支持均值原型的距离分类 [22]；DN4 将同类参考组成局部描述池，累加查询的近邻相似度 [23]；CAN 通过类参考与查询的相关性生成交叉注意，比较加权表示 [24]。这些工作分别提供全局原型、局部到类度量与查询相关取证的依据。

DeepEMD 通过交叉参考机制为密集表示中的结构元素赋权，并以局部匹配完成少样本分类 [25]；FRN 使用类内参考局部特征重构查询图，以岭回归重构误差形成类别分数 [26]。两者为局部参考利用提供了不同途径。本文借鉴关系算子，在已知类别和固定源参考库的闭集任务中研究中间层证据回写。

BiEnFRN 联合支持—查询双向重构、自重构与快照集成，提高细粒度少样本分类的区分能力 [27]。与 SAA 的联合注意 [21] 和重构式分类相比，本文 RCEW 将查询相对于各参考类别的距离转化为类别证据场，回写至中间特征，由后续骨干继续处理。

RCEW 保留参考权重、区域身份和类别组织，以传输边际聚合参考值，再形成查询相关的类间证据。回写消息显式包含类别比较结果，使后续网络直接处理参考提供的判别信息。其与普通参考特征回写、精细局部对应的差异通过内部替换实验检验。

2.4 受控扰动与解释约束

Li 等在 SAR 自动目标识别中量化目标、阴影与杂波的贡献及交互，并通过背景重标度研究非目标区域依赖 [28]。Meaningful Perturbation 通过显式输入操作研究固定模型的重要区域 [8]；ROAR 在训练和测试数据中一致移除信息后重新训练，强调区分模型敏感性与信息价值 [9]。Fourier Perspective 通过范数受控的频率扰动分析鲁棒性，说明高频或低频的作用不能一概而论 [29]。Right for the Right Reasons 则将解释约束纳入可微训练 [30]。

本文将受控输入分析细化为极化、目标相对区域和空间尺度，并同时记录正确类与竞争类变化。源端干预响应用于筛选判别优势保护对象，使训练约束与样本实际响应相联系。

在训练端，RSC 依据真实类梯度抑制主导隐藏特征，鼓励网络利用其他证据 [31]；输入梯度正则直接约束分类损失对输入的局部敏感性 [32]。本文比较有限幅度的区域尺度操作与匹配均值控制，对通过判别改善筛选的源样本施加教师分差下界保护。

PASTA 依据合成与真实图像的幅度谱差异，对较高空间频率施加相对更强的乘性扰动，以扩大训练分布覆盖 [33]。FGFL 根据少样本任务产生 DCT 频率掩膜，转换回图像后结合三元组与对比目标学习表示 [34]。本文的尺度操作同样发生于图像，但以极化、区域和类别竞争的操作效应确定保护对象；预测路径仅使用空间特征。

Contrastive-ACE 利用特征对标签的平均干预效应稳定性组织跨域学习 [35]。本文从可追溯的输入操作出发，以正确类—竞争类分差刻画响应变化，并将其用于样本级判别保护。

3 问题发现与受控干预证据

为了系统分析跨场景条件下的判别证据，本文构建了一个受观测、干预与替代证据比较启发的分层分析框架。如图 2 所示，自然观测用于揭示局部响应的场景依赖性，受控干预用于检验局部证据对类别竞争的影响，而替代证据比较进一步分析不同证据配置如何改变分类决策。基于此，本文进一步提出证据引导的学习框架。

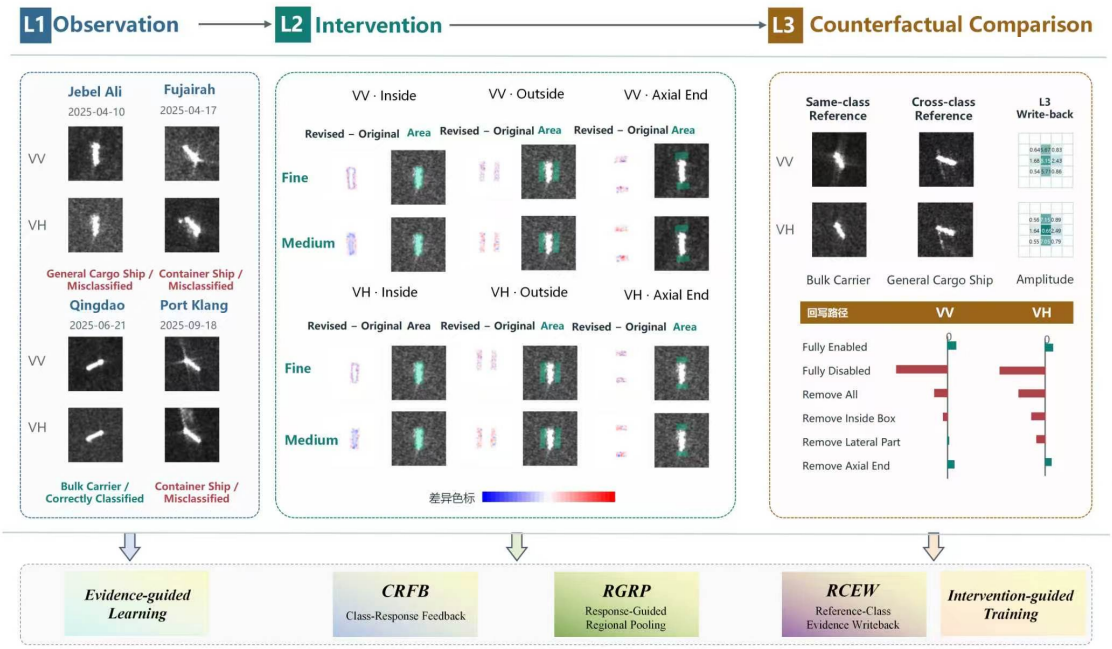


图 2 跨场景 SAR 船舶分类的分层判别证据分析框架。L1 展示同船跨场景观测中的极化响应与预测差异；L2 展示指定极化、区域和尺度的受控图像变化；L3 通过参考证据与回写路径的替代比较，分析分类决策的变化。下方给出证据分析与 CRFB、RGRP、RCEW 及干预引导训练的设计联系。

3.1 从自然不稳定到可检验问题

同船诊断使用自建 24 港语料中的 4744 次观测、2973 个船舶身份、18 港及八个输出类别。对每艘具有重复观测的船选择日期跨度最大的一对，得到 910 艘船的 1820 次观测，覆盖七类。表 2 给出三种代表性船型的三种子平均状态比例。

表 **2** 同船重复观测的分类状态，三种子平均。

船型	船对数	两次均正确（%）	一次正确一次错误（%）	两次均错误（%）
集装箱船	126	35.98	34.92	29.10
原油轮	100	27.67	54.67	17.67
普通货船	62	4.84	27.42	67.74

原油轮较多表现为观测相关的不稳定，普通货船则更多持续混淆。跨港与同港的粗比较还受到类别组成影响：未经类别等权，跨港 “两次均错误” 比例为 38.80%，低于同港 43.92%；按七类等权后分别为 50.94% 和 46.06%，方向反转。因此，任务需同时关注观测条件与类别组成，不能把跨港分组差异直接解释成港口的独立效应。

在相同源划分和配套训练的 Ridge 读出下，整图输入与卷积前框内掩膜输入的 OA/BA 分别为 35.139%/38.795% 和 32.610%/37.231%；原油轮召回分别为 53.580% 和 42.222%。整图输入在 4744 条观测中纠正 690 条、误判新增 570 条，净增加 120 条正确判断。这表明外围可见响应包含可利用的补充信息，也具有误导风险，需要区分其对具体类别竞争的作用。

3.2 干预定义与类别竞争

记双极化输入为 $x = (x^{VV}, x^{VH})$，固定诊断器为 T，真实类别为 y。以原图最强错误类作为固定竞争类别 $c^\star = \arg\max_{c \neq y} T_c(x)$，定义分差及操作效应：

$$\begin{aligned} m_{y,c^\star}(x) &= T_y(x) - T_{c^\star}(x), \\ \Delta m_a &= m_{y,c^\star}(x_a^I) - m_{y,c^\star}(x). \end{aligned} \tag{1}$$

其中 $a = (p, r, b)$ 指定极化 p、区域 r 和尺度 b。图像尺度分量取

$$D_f(I) = I - G_1(I), \qquad D_m(I) = G_1(I) - G_2(I). \tag{2}$$

G_σ 为标准差为 σ 个原生像素的高斯平滑。限定区域内通过平滑边缘掩膜削弱分量，保持另一极化、检测框、参考库和模型参数不变。结构操作使用共同 L_2 剂量，并设置具有相同区域净灰度变化的均值控制，以区分局部结构变化和平均亮度变化的作用。

式（1）可分解为 $\Delta T_y - \Delta T_{c^\star}$。因此，正确类分数下降并不必然意味着决策退化：如果错误竞争类下降更多，分差仍可改善。为排除竞争类切换造成的虚假改善，选样时进一步检查各自最强错误类定义的分差 $m_{\max}(x) = T_y(x) - \max_{c \neq y} T_c(x)$。

3.3 极化与区域决定操作效应

在自建 24 港语料的 104 艘船、209 次观测、31 个过境和 6 港干预队列中，VH 框内细尺度削弱平均损害正确类别优势，VH 侧向中尺度削弱平均改善优势，同一侧向中尺度操作在 VV 中则为负。表 3 以诊断器分差报告效应及船级 95% 区间。

表 **3** 极化与区域干预的船均分差变化。

操作	平均 Δm	船级 95% 区间	相对同均值控制的剩余效应
VH 框内细尺度削弱	−0.003910	[−0.005232, −0.002528]	−0.002997
VH 侧向中尺度削弱	+0.002023	[+0.000882, +0.003169]	+0.001417
VV 侧向中尺度削弱	−0.001454	[−0.002477, −0.000476]	−0.001147

类别进一步调节操作效应：VH 侧向中尺度削弱在 9 艘集装箱船上的平均分差变化为 +0.008422，在 7 艘散货船上为 −0.008180。相反的作用方向支持保留极化和区域身份，并依据类别响应学习取证方式。

3.4 类别竞争的案例分析

图 3 的散货船 10488 展示了类别竞争的变化。仅削弱 VH 框内细尺度后，散货分数增加 0.11492，错误原油轮分数下降 0.16278，分差提高 0.27769；均值控制仍误判。对照案例化学品船 26628 则同时降低正确类并抬高海工竞争类，产生误伤。局部证据的效用因此需落实到正确类与竞争类的相对变化。

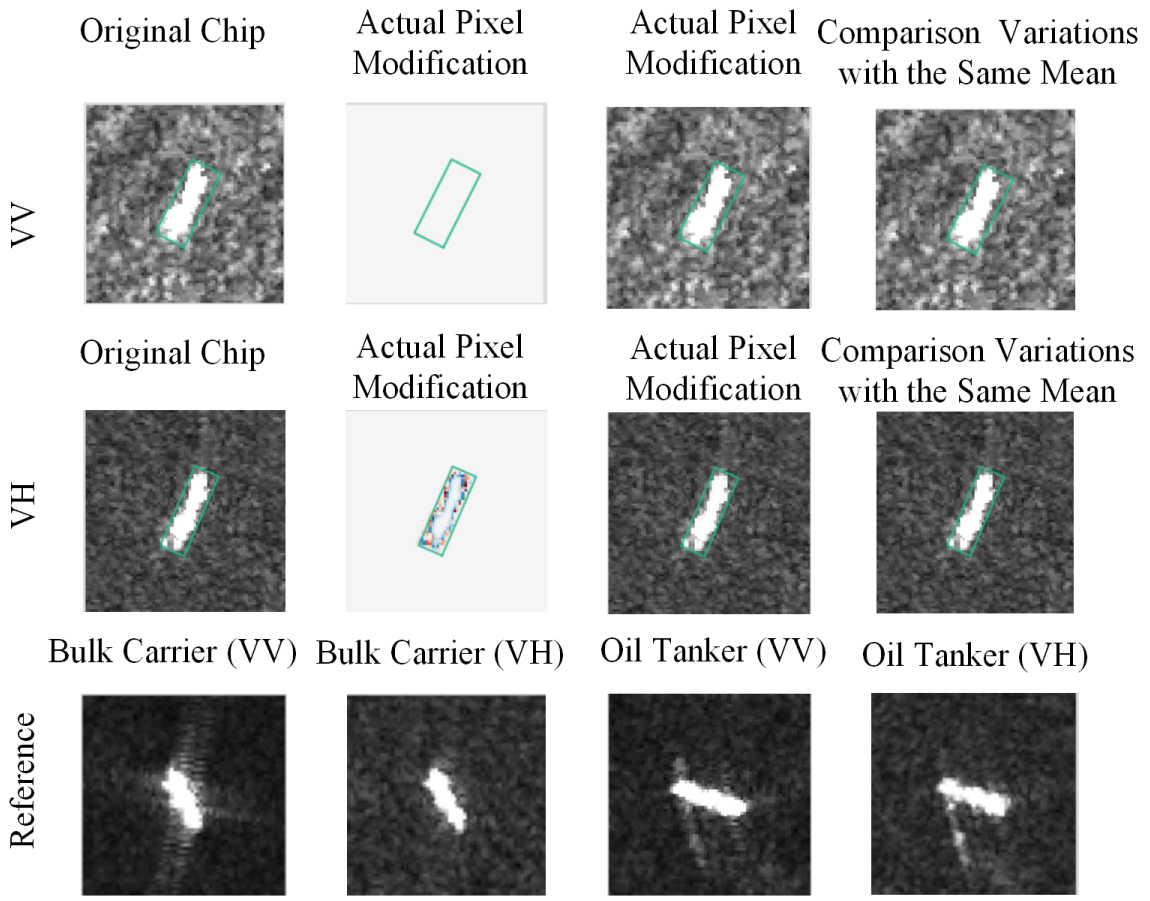


图 3 散货船 10488 的受控干预与实际参考。上两行依次展示 VV 和 VH，各列为原图、像素变化图、干预后图像及匹配均值控制；下方为实际同类与混淆类参考。VV 保持不变，VH 框内细尺度削弱改变类别竞争，均值控制仍误判。结果来自固定诊断模型。

3.5 判别机制与设计依据

自然观测和受控干预共同表明，局部证据的判别作用具有条件性：不同极化、区域和尺度中的响应可能改变不同的类别竞争关系。固定模型上的输入操作建立了“局部响应变化—类别竞争变化”的可追溯联系，其效应对应分类系统对指定操作的依赖。基于这些证据，本文从三个层次组织模型设计。

首先，仅依据激活强度不足以确定局部证据的判别方向，因而保留整体均值上下文，并建立局部内容与相对类别响应的联系，对应 CRFB。其次，同一操作在框内和侧向可能产生不同作用，因而保留极化及目标相对区域身份，在区域内部开展类别引导取证，对应 RGRP。最后，纠错既可能来自增强正确类，也可能来自削弱混淆类，因而将查询与各类源参考的比较显式转换为相对类别证据，对应 RCEW。

上述分析为模块提供设计依据，配套训练与替换实验进一步检验其分类效用。训练端则利用源样本的实际干预响应确定判别保护对象，使证据分析参与优化过程，而不将一种固定的图像削弱操作应用于所有查询。

4 方法

4.1 任务与整体结构

本文研究检测后、固定类别集合下的跨场景船舶分类。整体网络依次组织单图类别响应、目标相对区域和源参考类别关系，使局部证据在特征形成、区域汇总和跨样本比较三个环节参与判别。

给定固定检测流程定位的目标 chip、OBB 与极化可用性标记，模型预测 K 个已知船型之一。网络在源场景的标注样本上学习，在船舶身份和采集过境均隔离的目标场景中评价。公开集分类实验取 $K = 4$，自建数据采用八类标签。源参考库为 $\mathcal{R} = \{(x_j, y_j)\}_{j=1}^{B}$；公开集取 $B = 32$，每类 8 个参考，自建数据取 $B = 16$，每类 2 个参考。查询标签不参与预测；参考选择排除与查询同船或同过境的观测，并按极化可用性屏蔽无效关系。

输入按目标中心在原生像素网格裁剪或补零至 160×160，保留已有 chip 的像素尺度，有效范围掩膜排除补零。VV 与 VH 分别前向并共享 ResNet-50[36] 卷积权重；CRFB、RGRP 及 RCEW 的投影与回写使用极化专属参数，生成通道度量的小网络共享。各极化依据检测框有效性确定是否进入分类：某一极化未通过目标定位或置信度要求时，仅屏蔽该分支，仍使用另一有效极化。这对应检测后分类中部分极化定位失败的情况，原始影像本身可同时具备 VV 和 VH。

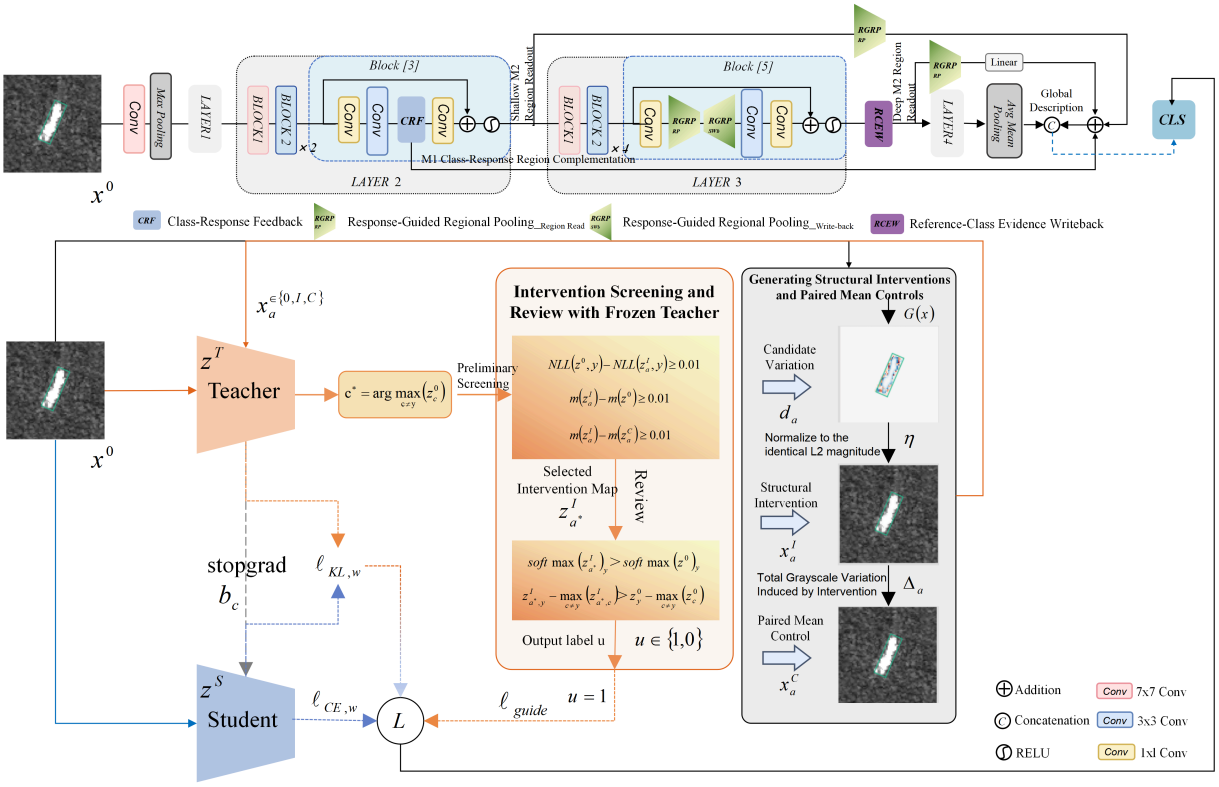


图 4 整体结构及受控训练路径。图中展开单极化路径，两极化共享骨干、使用专属证据处理参数；同一区域的多层摘要先相加，再将三区域与全局描述拼接。RCEW 读取源参考。下部为干预适配阶段的选样和判别保护路径，KL 保护作用于教师原本判对的样本，预测时仅执行上部网络。

CRFB 位于 layer2 末块的 conv2 激活之后；RGRP 在 layer3 末块的 conv1 激活后执行区域池化回写，并从 layer2 输出和 RCEW 更新后的 layer3 输出读取区域摘要；RCEW 位于 layer3 与 layer4 之间。各极化分别执行上述处理，全局描述来自 layer4。区域池化保持特征图空间尺寸，与骨干下采样各司其职。

4.2 类别响应反馈模块（CRFB）

局部高响应可能同时支持多个易混淆类别，仅依据响应强弱进行重标定，难以描述它对类别竞争的不同作用。CRFB 以当前类相对其他类的响应为条件，计算其与局部内容变化的关联，并将这种关联反馈至中间特征；均值支路同时保留整体上下文。

设某一极化的输入为 $X_1(u) \in \mathbb{R}^{128}$，$u$ 表示空间位置，有效面积占比为 $o(u)$，归一化权重为 $\omega(u) = o(u)/\sum_v o(v)$。屏蔽无效位置后，以两个 1×1 卷积得到 32 维值特征 $V_1(u)$ 和 K 维候选类别响应 $A(u)$。记 $\bar{V}_1 = \sum_u \omega(u)V_1(u)$，相对类别响应及其标准化量为

$$
\begin{aligned}
d_k(u) &= A_k(u) - \frac{1}{K-1}\sum_{j\neq k} A_j(u), \\
\bar{d}_k &= \sum_u \omega(u) d_k(u), \\
s_k(u) &= \frac{d_k(u) - \bar{d}_k}{\sqrt{\sum_v \omega(v)(d_k(v) - \bar{d}_k)^2 + 0.01}}.
\end{aligned}
\tag{3}
$$

以相对响应和局部值的共同变化形成类别相关摘要：

$$
\begin{aligned}
C_k &= \sum_u \omega(u)\,[V_1(u) - \bar{V}_1]\, s_k(u), \\
R_1(u) &= \frac{1}{K}\sum_k \tanh(s_k(u))\,\tanh(L_k(C_k)).
\end{aligned}
\tag{4}
$$

C_k 描述低维内容与标准化类别响应之间的交叉统计，L_k 为含偏置的仿射映射。令均值变换 $U_0 = W_0\tanh(L_0(\bar{V}_1))$，与关系支路共同生成有界门控并反馈至原特征：

$$
\begin{aligned}
G_{\mathrm{CRFB}}(u) &= o(u)\tanh\{U_0 + W_1 R_1(u)\}, \\
X_1'(u) &= X_1(u) + 0.3X_1(u)\odot G_{\mathrm{CRFB}}(u).
\end{aligned}
\tag{5}
$$

输出映射零初始化，使训练从原特征路径开始。类别辅助读出利用源标签约束候选响应。X_1' 经过该 block 的 conv3、归一化与残差相加形成 layer2 输出 F_2；类别响应保留给后续区域读出使用。

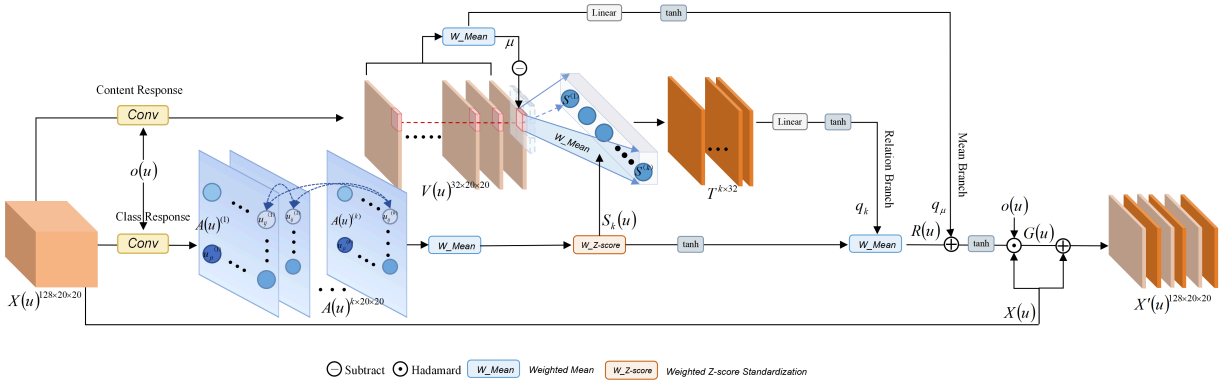


图 5 CRFB。当前类相对其他类均值的响应经标准化，与内容形成交叉统计 C_k，再与内容均值分别变换并生成局部门控。输出投影恢复 128 通道，反馈增益为 0.3，有效面积占比屏蔽补零位置。

式（4）中的交叉统计同时包含内容偏离和类别响应偏离，反馈因而不只依赖某个位置的激活大小。相比 CAM 的类别激活定位 [14] 与 GSoP 的特征统计重标定 [17]，这里将候选类别相对响应与中心化局部内容关联起来，形成位置相关的中间层更新。CRFB 输出的类别响应还继续用于 RGRP，在特征反馈与区域取证之间共享判别依据。

4.3 响应引导区域池化（RGRP）

统一的全局汇总会压缩船体与不同方向外围的空间差别，而预先划定区域也不能保证区域内各位置具有相同的判别价值。RGRP 结合目标几何与 CRFB 类别响应，分别处理“从哪个区域读取”及

“区域内如何加权” 两个问题。该模块包含骨干内部的区域池化回写，以及面向分类的多层区域读出。

4.3.1 区域身份与内部回写

以 OBB 长轴建立目标相对坐标，构造框内、轴端与侧向三个区域。框内为长宽 L, W 的软矩形；轴端为长轴扩展至 $1.5L$ 的矩形减去框内；侧向为宽度扩展至 $2W$ 的矩形减去框内。区域与有效输入范围相交，以特征网格实际面积占比表示 $m_r(u)$。两轴端对称处理，无需船首、船尾标注。

对于特征 F，区域均值为

$$\pi_r(u) = \frac{m_r(u)}{\sum_v m_r(v)}, \qquad \mathrm{Pool}_r(F) = \sum_u \pi_r(u) F(u). \tag{6}$$

令 $t_r = \mathrm{Pool}_r(X_3)$。空区域返回零并屏蔽更新。layer3[5] 中的内部 RGRP 以区域专属两层映射 ϕ_r 变换摘要，只回写至相应区域：

$$\begin{aligned} X_3'(u) &= X_3(u) + \sum_r \widetilde{m}_r(u)\phi_r(t_r), \\ \widetilde{m}_r(u) &= m_r(u) / \max\{1, \sum_j m_j(u)\}. \end{aligned} \tag{7}$$

其中 X_3 为 conv1 激活后的 256 通道特征。区域专属变换保留框内、轴端与侧向的身份，不将三者合成同一个上下文再广播到全图。回写保持空间尺寸，使随后 3×3 卷积同时读取局部内容与对应区域的摘要。另两处区域读出仅汇总特征，用于最终分类。

4.3.2 由 **CRFB** 响应指导浅层取证

CRFB 读取 layer2[3] 中的 128 通道特征，其响应与该 block 末端 512 通道特征 F_2 位于同一 20×20 网格。在有效范围内标准化相对类别响应，得到有界评分 $q_k(u) = 2\tanh(s_k(u))$。在每个区域内分别归一化：

$$\begin{aligned} \alpha_{r,k}(u) &= \frac{m_r(u) \exp q_k(u)}{\sum_v m_r(v) \exp q_k(v)}, \\ t_{r,k} &= \sum_u \alpha_{r,k}(u) V_2(u). \end{aligned} \tag{8}$$

其中 $V_2 = W_V^{(2)} \mathrm{LN}(F_2)$ 为 512 维到 32 维的值投影。同时保留均匀摘要 $t_{r,0} = \sum_u \pi_r(u) V_2(u)$；四类时五个摘要拼接为 160 维。记 $t_r^{\mathrm{cat}} = [t_{r,0}; \ldots; t_{r,K}]$，$\sigma_{p,r} = \mathrm{stopgrad}\{\mathrm{RMS}(\mathrm{Pool}_r(F_{2,p}))\}$，补充量为

$$\delta_{p,r}^{(2)} = 0.1 \sigma_{p,r} \tanh(W_p^{\mathrm{read}} t_r^{\mathrm{cat}}). \tag{9}$$

W_p^{read} 将 $32(K+1)$ 维映射回 512 维，四分类时输入为 160 维，八分类时为 288 维；该映射零初始化，同一极化的三区域共享。所有候选类别同时参与，既不输入查询真值，也不按当前预测的单一类别硬路由。输出仍位于原有区域槽位，保留均值信息，并用有界残差限制新增路径的幅度。式（8）回答 “在这一几何区域内哪些位置更有助于类别区分”，式（6）回答 “该区域总体包含什么”。

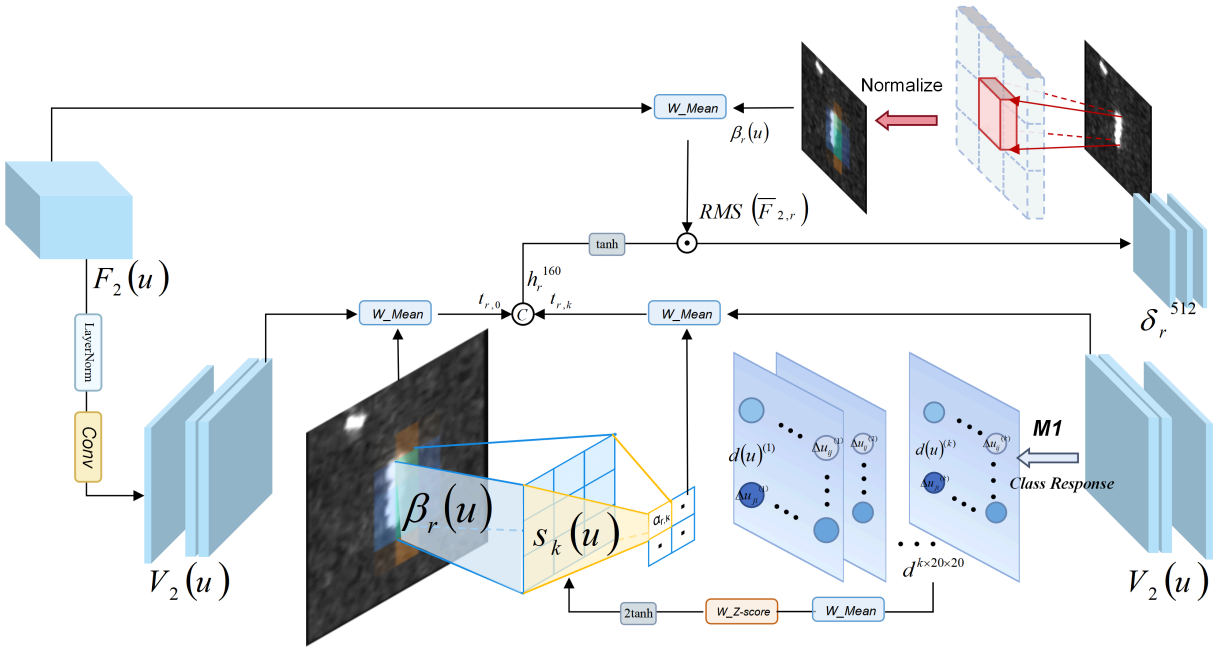


图 6 CRFB 引导的 RGRP 浅层读出，以四分类为例。类别响应 $A(u)$ 与内容投影 $V_2(u)$ 在区域内联合取证；均值及类别加权摘要拼接，经 160 到 512 维投影和有界变换形成补充量。区域归一化权重为 π_r，补充增益为 0.1，尺度参照采用停止梯度的 RMS。

区域权重依据特征中心的覆盖面积计算；由于卷积感受野交叠，区域描述保留的是计算位置与目标几何的关系。

4.4 参考类别证据回写（RCEW）

CRFB 和 RGRP 主要组织当前图像内部的证据；当查询中某些局部响应同时接近多个船型时，还需要比较它与不同类别参考之间的关系。RCEW 利用固定源参考库构造这种比较，将“局部内容更接近哪类参考、相对其他类优势多大”转化为类别证据场，再反馈至骨干。参考信息因此参与后续特征计算，而不只提供末端相似度分数。

4.4.1 比较描述与值描述分离

RCEW 使用源参考库补充单图判别。首先对固定锚点路径中的 layer1 和 layer2 特征分别读出区域局部描述，通道数为 256 和 512。每极化各自投影至 32 维并拼接，再分别生成 32 维比较键 k 与值 v。键经归一化用于比较，值用于构造判别消息。局部槽位保留框内 8、侧向 8、轴端 4 的组织，空槽和不可用极化不参与参考比较。

参考比较使用固定锚点路径的 layer1 和 layer2 表示，以在读出优化期间保持查询—参考表征一致。

对某区域的合法源参考，按参考标签形成类均值 μ_c 和其他类均值 $\mu_{\neg c}$，记 $a_c = [\mu_c; \mu_{\neg c}; \mu_c - \mu_{\neg c}]$，由共享小网络生成有界正通道度量：

$$
\begin{aligned}
w_c &= 1 + 0.5 \tanh \psi(a_c), \\
S_{sij} &= \cos(\sqrt{w_{y_s}} \odot k_i^q, \sqrt{w_{y_s}} \odot k_{sj}^{\mathrm{ref}}).
\end{aligned}
\tag{10}
$$

这里 i, j 分别是查询与参考的局部槽位，s 是参考船，y_s 是已知源标签；为简洁省略极化和区域索引。通道分支以 32 维类均值、其他类均值及其差拼接为 96 维，经 96→16→32 的小网络生成 $w_c \in (0.5, 1.5)^{32}$。它既用于键的加权余弦比较，也用于后续值距离，并非独立的分类头。

空间分支先计算查询槽位对类别 c 的最佳相似度 $B_{ic} = \max_{s:y_s=c,j} S_{sij}$，只在合法参考和非空槽位上取最大值。再以 $b_{ic} = B_{ic} - \mathrm{mean}_{c' \neq c} B_{ic'}$ 表示相对其他可用类的优势，形成比较 logit

$L_{sij} = S_{sij} + b_{i,y_s}$。只有一个可用类别时令 $b_{ic} = 0$。带未匹配槽的 Sinkhorn 归一化产生有效传输 T_s，非法位置在归一化前屏蔽。通道与空间分支因此是耦合的比较步骤，而不是两个结果直接相加的独立分支。

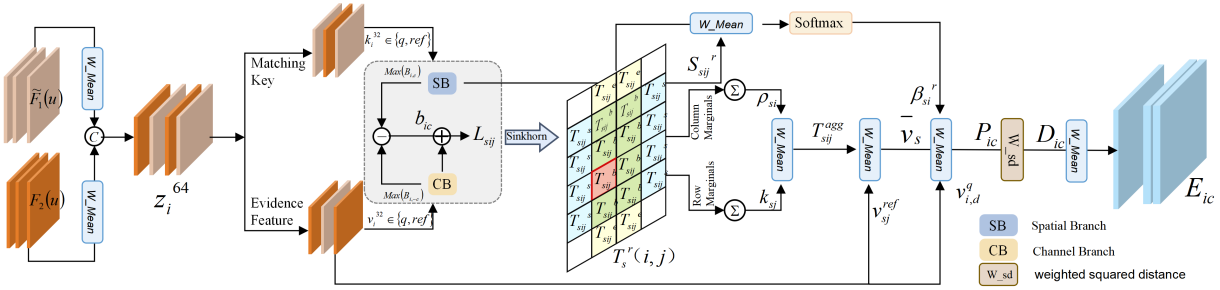


图 7 RCEW 比较、类别聚合与证据回写。通道度量参与空间相似度，本类最佳相似度相对其他类最佳相似度均值的优势调节传输。比较路径保留原传输，值路径采用边际外积聚合。行边际 ρ_{si} 对应查询槽位，列边际 κ_{sj} 对应参考槽位，外积除以有效总质量 M_s。64 维描述包含逐层投影，值距离取负并经温度缩放和类别中心化形成证据，再经空间分配和 1×1 映射残差回写。

4.4.2 类别条件的参考聚合

记 T_s 的有效行、列边际为 $\rho_{si} = \sum_j T_{sij}$、$\kappa_{sj} = \sum_i T_{sij}$，有效总质量为 $M_s = \sum_i \rho_{si}$。选用的聚合版在值传递阶段使用

$$T^{\text{agg}}_{sij} = \frac{\rho_{si}\kappa_{sj}}{M_s}, \qquad \bar{v}_s = \frac{\sum_j \kappa_{sj} v^{\text{ref}}_{sj}}{M_s}. \tag{11}$$

上述等式适用于分母非零的位置，其余位置屏蔽。$\bar{v}_s$ 实际是按列边际汇总的区域参考值，不再保留查询槽位到参考槽位的一一精细搬运。参考权重仍依赖原传输与相似度：先计算 $g_{si} = \sum_j T_{sij} S_{sij} / \rho_{si}$，再在合法参考间令 $\beta_{si} = \text{softmax}_s(g_{si}/0.1)$。类参考表示为

$$P_{ic} = \frac{\sum_{s:y_s=c} \beta_{si} \bar{v}_s}{\sum_{s:y_s=c} \beta_{si}}. \tag{12}$$

边际聚合保留查询相关的参考选择及类内组织，将局部值对应压缩为区域参考摘要。这样，比较路径负责确定值得参考的响应及参考样本，值路径则以类别为单位汇总可传递的内容；二者通过传输边际和参考权重相联系。

4.4.3 类别证据场及空间回写

查询值与各类参考表示的距离形成候选类别证据，取 $e_{ic} = -D_{ic}/0.1$，并在可用类别中中心化：

$$\begin{aligned} D_{ic} &= \sum_d w_{c,d} (v^q_{i,d} - P_{ic,d})^2, \\ \tilde{e}_{ic} &= e_{ic} - \frac{1}{|\mathcal{C}_i|} \sum_{c' \in \mathcal{C}_i} e_{ic'}. \end{aligned} \tag{13}$$

屏蔽不可用类别后，以局部槽位的空间占比 $\eta_i(u)$ 将证据落回 layer3 网格：

$$\begin{aligned} E_c(u) &= \sum_i \eta_i(u) \tilde{e}_{ic}, \\ F_3^+(u) &= F_3(u) + 0.1 W_p^{\text{out}} E(u). \end{aligned} \tag{14}$$

W_p^{out} 为 K 个类别证据通道到 1024 个骨干通道的 1×1 卷积。距离越小，候选类别的原始证据越高；类别中心化进一步突出相对优势，使回写消息表达类间比较，而不是无类别区分的参考内容。layer4 继续加工 F_3^+，深层 RGRP 从该特征读取区域摘要。RCEW 由此将跨样本的类间关系引入特征流，补充 CRFB 的单图调节和 RGRP 的区域汇总。

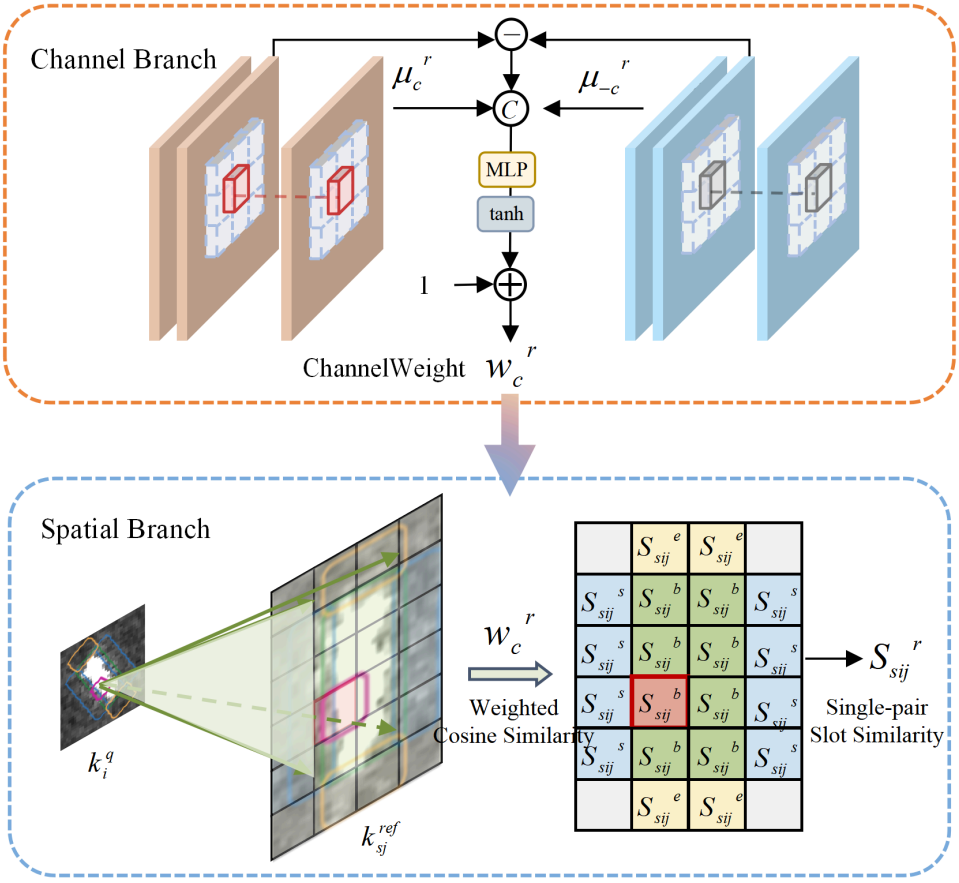


图 8 RCEW 的通道与空间比较分支。类内 / 类外参考统计经 $1+0.5\tanh(\cdot)$ 生成正通道度量 w_c，同时作用于局部键相似度 S_{sij} 和值距离 D_{ic}；空间相似度进一步用于图 7 的类别相对优势与匹配。

最后的区域读出优化固定参考路径，式（14）实现为 $F_3^+ = F_3^{\text{live}} + \Delta F_3^{\text{anchor}}$，其中锚点残差由已训练的 RCEW 产生。

4.5 多层融合与最终分类

多层融合在相同几何区域内整合不同深度的表示，并在不同区域之间保留独立描述。layer2 提供较细的空间网格，RCEW 更新后的 layer3 包含区域上下文及参考类别证据，layer4 则形成全局表示。

对极化 p 和区域 r，令 $t_{p,r}^{(2)} = \text{Pool}_r(F_{2,p})$、$t_{p,r}^{(3)} = \text{Pool}_r(F_{3,p}^+)$，最终区域描述为

$$R_{p,r} = t_{p,r}^{(2)} + D_p t_{p,r}^{(3)} + \delta_{p,r}^{(2)}. \tag{15}$$

深层线性投影 D_p 将 1024 维映射为 512 维，使相同区域的浅层、深层和引导补充项可以相加；不同区域之间保持拼接。layer4 得到有效范围全局平均描述 $g_p \in \mathbb{R}^{2048}$，每极化表示为 $h_p = [g_p; R_{p,\text{body}}; R_{p,\text{end}}; R_{p,\text{side}}] \in \mathbb{R}^{3584}$。将可用极化描述及标记拼接为 $h = [a_{VV}h_{VV}; a_{VH}h_{VH}; a_{VV}; a_{VH}]$，得到分类分数：

$$z = W_{\text{head}} h + b_{\text{head}}. \tag{16}$$

$a_p \in \{0, 1\}$ 为极化可用性，分类输入共 7170 维。最终 softmax 输出 K 类概率。

4.6 分阶段优化及干预指导约束

训练先建立区域表征，再引入参考类别关系及类别响应引导。各阶段固定不参与优化的路径，保持当前比较和读出的特征基础一致；受控干预在其中用于选择判别保护对象，预测路径仍使用未经干预的输入。

网络采用分阶段优化。首先从 ImageNet 预训练权重出发，在训练子集上更新 RGRP、分类头及 layer3 末块的三层卷积，建立区域证据表征；随后在另一源子集上执行干预指导适配，仅更新上述三层卷积。合并两个源子集后，依次训练 RCEW 及分类头、CRFB 及相邻 conv3 和分类头、响应引导区域补充及分类头。CRFB 阶段以 0.02 权重加入类别响应辅助交叉熵。所有阶段仅使用源标签，未参与当前阶段优化的部分保持固定。

源样本权重按类别内独立船数和同船观测次数修正，参考训练及其后阶段对阶段起点分差小于 1 的源难例乘 2。区域补充阶段训练 180 步，batch 为 24；输出映射、值投影、分类头的基础学习率分别为 $10^{-3}, 3\times10^{-4}, 10^{-5}$。各阶段使用 AdamW，权重衰减 0.01、梯度裁剪阈值 5，BN 统计不更新。完整模型比较从共同预训练起点重复全部阶段；算子机制实验则固定同一上游，仅重复待比较阶段，两类结果分别报告。

训练框架还包含干预指导约束。对源样本，以式（1）固定竞争类，要求结构操作同时降低交叉熵、提高竞争类分差，并优于匹配均值控制，三个初筛阈值均为 0.01。随后复核正确类概率与 $m_{\max}$ 均提高，将通过样本标记为 $u_n=1$。筛选直接使用干预图的教师预测。

所有原图均接受交叉熵监督；教师原本正确的样本额外接受分布保持约束；$u_n=1$ 的样本进一步接受原图教师判别优势下界保护。以 n 表示训练样本，$z_n^0=T(x_n^0)$、z_n^S 分别为原图教师与学生分数，$b_{nc}=\mathrm{stopgrad}(z^0_{n,y_n}-z^0_{nc})$，则

$$\begin{aligned}\ell_{\text{guide},n}&=\frac{1}{K-1}\sum_{c\neq y_n}[b_{nc}-(z^S_{n,y_n}-z^S_{nc})]_+^2,\\ \mathcal{L}_{\text{guide},w}&=\frac{\sum_n w_n u_n \ell_{\text{guide},n}}{\sum_n w_n}.\end{aligned}\tag{17}$$

$$\mathcal{L}_{\text{adapt}}=\mathcal{L}_{\text{CE},w}+0.1\mathcal{L}_{\text{KL,correct},w}+\lambda\mathcal{L}_{\text{guide},w}.\tag{18}$$

教师量均停止梯度。该约束以教师原图分差为下界，而非以干预图的更高分差作为学生必须达到的目标。未通过筛选的样本仍参与分类监督，教师原本判对时也参与 KL 保持，仅不施加式（17）的额外保护。预测时输入原始 SAR 图像，不执行依赖真实类别的干预筛选。完整模型及配套对照均由各自的源端教师生成筛选标记，并采用相同的适配规则。

5 实验设置

5.1 数据集介绍

本文使用 OpenSARShip 2.0（OSS2）和自建 24 港数据集开展跨场景分类实验，分别考察公开四分类与自建八分类任务。表 4 汇总实际整理的数据规模；公开数据数量按本研究解析清单统计。每条观测对应一个船舶目标，VV/VH 为其两种极化视图。

表 **4** 数据集组成。

数据集	观测规模	类别与采集
OSS2	6,780 条 GRDH 记录	本文分类取 4 类；训练集 719、验证集 228、测试集 378 条
自建 24 港	38,091 条观测；18,766 个非空 MMSI	8 类、24 港、841 个 IW-GRDH 产品

公开数据集。 OSS2 沿用原生船舶裁片及元数据，本文使用 IW-GRDH 产品。细粒度标签仅保留与任务类别一致的记录，笼统 Cargo 和 Tanker 标签不直接映射为普通货船或原油轮。OSS2 分类比较采用散货船、普通货船、化学品 / 成品油轮和集装箱船四类图像，以保证各类参考与输入覆盖。

公开集各极化分别执行固定 OBB 定位，检测置信度达到 0.25 且几何有效时进入对应分支。在 OSS2 训练集、验证集和测试集中，分别有 48、22 和 30 条观测仅一个极化满足条件；这些观测的另一极化原始文件仍存在。模型通过式（16）的可用性标记处理该情况，符合检测后分类中某一极化定位不成功、另一极化仍可用于识别的输入条件。

自建 **24** 港数据集。数据来源为 Sentinel-1A 和 Sentinel-1C 的 IW-GRDH 双极化产品，依据 AIS 关联的船舶身份与类型组织八类目标，保存 VV/VH 图像、源产品号、港口、裁片位置及目标几何信息。采集时间为 2025 年 1 月 1 日至 2026 年 2 月 24 日；38,091 条观测中，32,184 条来自 Sentinel-1A，5,907 条来自 Sentinel-1C。841 个产品按平台与绝对轨道合并为 720 个过境组，避免将同次过境的不同产品切片视为独立观测条件。本文使用地理处理后的 8 位动态裁片，不将其视为原始复数 SAR。模型输入遵循第 4.1 节的原生像素裁剪 / 补零规则；可恢复的 10 m 像素间距不等同于传感器空间分辨率。

表 5 对照源产品、像素表示与预处理。公开集提供的 32 位原始幅度和定标裁片是不同文件分支，本文分类输入采用 8 位灰度裁片；自建数据同样采用 8 位图像。标称像素间距用于描述采样格网，不等同于传感器空间分辨率。

表 **5** 各数据集的 **Sentinel-1** 产品、像素表示与预处理对照。

对照项	OpenSARShip 2.0	自建 24 港 SAR–AIS
源产品	Sentinel-1 IW-GRDH	Sentinel-1A / 1C IW-GRDH
极化	VV/VH	VV/VH
源产品标称像素间距	约 10 × 10 m	约 10 × 10 m
像素表示	提供原始幅度、定标与灰度裁片	地理处理后的 8 位灰度 PNG 动态裁片
辐射定标	提供定标裁片，具体参数未详述	使用灰度显示值；已追溯服务器分支未应用定标 LUT
几何处理	沿用数据集裁片；论文未明确重投影设置	UTM 地理编码、10 m 输出格网；重采样方式随处理批次不同
灰度转换	提供灰度图，映射参数未详述	按极化作百分位拉伸；已追溯服务器分支采用整景 2% / 98% 阈值
本文分类输入	8 位灰度裁片	8 位灰度裁片

图 9 展示 24 港的地理位置与港区观测分布。表 6 列出各港的观测规模与诊断覆盖。各港含 64 至 5,756 条观测，实际覆盖 3 至 8 类；类别分布差异较大，因此同时采用 OA、BA 及逐类分析。198 条记录缺失 MMSI，同船分析仅使用可核查的非空身份。

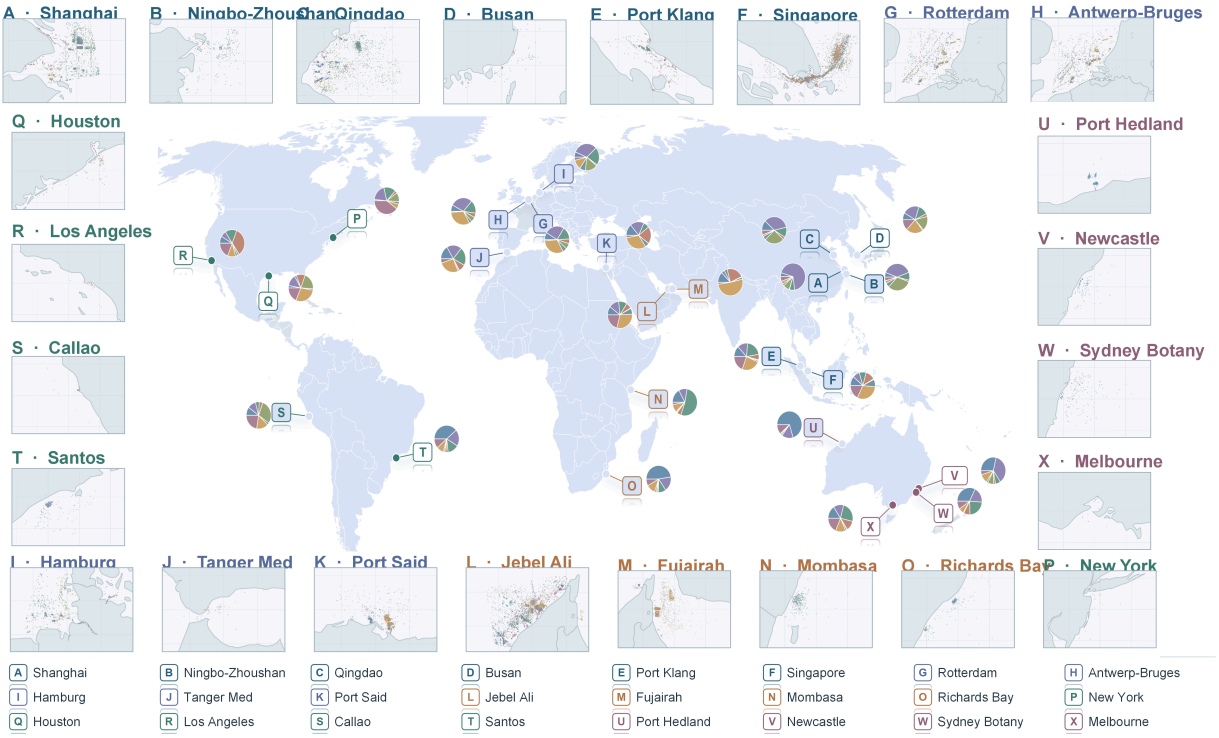


图 9 自建 24 港数据集的地理位置及港区观测分布。世界地图中的字母标记与周围同字母港区子图对应，底部列出港口名称。

表 **6** 自建 **24** 港逐港组成及诊断覆盖。

港口	总库观测	实际类别数	诊断观测
Antwerp-Bruges	886	3	0
Busan	871	3	48
Callao	476	8	14
Fujairah	1,158	3	178
Hamburg	1,619	3	0
Houston	804	8	9
Jebel Ali	4,602	8	1,046
Los Angeles	583	8	158
Melbourne	64	3	0
Mombasa	149	7	12
New York	470	8	0
Newcastle	299	7	25
Ningbo-Zhoushan	5,756	3	292
Port Hedland	859	6	53
Port Klang	3,425	8	1,238
Port Said	1,895	8	150
Qingdao	1,981	3	0
Richards Bay	744	8	241
Rotterdam	573	3	36
Santos	1,658	8	325
Shanghai	2,390	3	0
Singapore	5,259	8	821
Sydney Botany	304	8	10
Tanger Med	1,266	8	88
合计	38,091	合计 8 类	4,744

表 7 给出八类组成。诊断队列包含 4,744 条观测、2,973 艘船和 18 港；同船最大日期跨度配对子集包含 910 艘船、1,820 条观测，覆盖 13 港和 7 类。受控干预队列按第 3.3 节的条件另行组织。

表 **7** 自建数据集类别分布。

船型	总库观测	诊断观测
散货船	11,128	1,290
渔船	8,599	145
普通货船	5,929	439
化学品 / 成品油轮	5,827	1,480
集装箱船	2,208	519
原油轮	1,757	405
拖轮 / 拖带船	1,478	202
海工补给船	1,165	264
合计	38,091	4,744

5.2 跨场景划分与参考设置

根据产品元数据恢复平台与绝对轨道，合并同次过境的相邻产品切片，再划分训练集、验证集和测试集。三个集合之间隔离船舶身份及过境组，测试查询不使用目标标签。该协议以未见船舶和未见过境组织跨场景测试，地理水域随实际产品覆盖变化，不要求训练与测试来自完全不同的港口。自建 24 港的场景描述同时保留港口归属，以分析同港和异港条件下的观测差异。表 8 给出 OSS2 类别组成。

表 **8 OSS2** 四分类划分。括号内为独立船数。

集合	散货船	普通货船	化学品/成品油轮	集装箱船	总观测/船数/过境
训练集	221（216）	73（71）	141（137）	284（259）	719 / 683 / 13
验证集	87（84）	23（22）	29（29）	89（88）	228 / 223 / 4
测试集	132（128）	26（26）	83（81）	137（134）	378 / 369 / 5

OSS2 训练集进一步分为 478 条表征训练观测和 241 条干预适配观测。固定 32 个源参考，每类 8 个，均来自表征训练子集；测试集覆盖五个过境。

自建 24 港完整训练采用 20,653 条合法训练记录，其中 19,981 条用于表征训练、672 条用于干预适配；验证集含 160 条观测、158 艘船和 3 个过境，测试集含 3,075 条观测、1,950 艘船和 85 个完整过境组。完整过境组由卫星平台、绝对轨道号及数据获取批次（datatake）共同确定；测试集对应 81 个平台—绝对轨道组合，其中 4 个组合各包含两个 datatake。训练集覆盖 24 港，测试集覆盖 18 港，沿用既有身份与过境隔离划分。源参考共 16 艘，每类 2 艘。类别反馈和区域读出阶段各遍历训练数据两轮，其余阶段沿用相应训练配方。

5.3 实现细节与优化协议

完整模型与普通骨干、匹配位置的 SE[15] 对照从同一 ImageNet 起点训练，均使用双极化输入、相同源划分和训练策略。SE 以压缩比 16 插入 layer2 与 layer3 末块的残差相加前。表征学习、干预适配和参考训练分别为 8、6 和 4 轮；公开集的类别反馈与区域补充各 180 步，自建数据按第 5.2 节的两轮遍历执行。移除组件时保留相应阶段的分类头训练。除各模块外，骨干可更新范围为 layer3 末块的三层卷积及 layer2 末块的 conv3，其余卷积固定。

完整模型、普通骨干和 SE 分别在 OSS2 验证集上比较基础学习率倍率 1.0 和 0.3，以 BA、OA、NLL 依次选择，完整模型与普通骨干选择 1.0，SE 选择 0.3。删除组件的模型继承完整模型倍率。完整训练使用种子 17、29 和 43。配对区间按船舶重采样，保留同船各观测及种子的对应关系。

上述配置称为分阶段训练版，用于共同起点的主比较和组件消融。另以各自分阶段终点初始化完整模型的全骨干微调版，联合更新骨干与 CRFB、RGRP、RCEW，BN 运行统计保持固定。微调仍使用相同训练、验证和测试划分，参考特征由当前骨干重新计算，不沿用旧骨干的特征缓存。两个优化协议的结果分别列示，分阶段消融用于解释对应训练配置，不作为微调版的重新训练消融。

OSS2 微调使用 AdamW、权重衰减 0.01、有效 batch 24、梯度裁剪 5 以及两轮预热后的余弦学习率。骨干和模块的选定学习率均为 10^{-4}；损失为类别 / 船舶平衡交叉熵与权重 0.02 的类别响应辅助监督。最多训练 30 轮，至少 12 轮后允许连续 8 轮验证性能不改善时早停。解冻范围与学习率先在 seed17 验证集上比较六组配置，再固定全骨干、10^{-4} 的组合复核 seed29、43。微调继承已完成的干预指导训练，不在此阶段重新生成筛选标记。

充分训练的普通 ResNet-50（R50-Tuned）从 ImageNet 起点独立训练，骨干与分类头学习率分别为 10^{-4} 和 10^{-3}，最多 60 轮，至少 30 轮后按 15 轮耐心值早停。CPINet 采用适配本任务输入与标签的独立实现，从随机初始化训练 300 轮，在验证集选择学习率。二者与完整模型共享数据划分和评价对象，但初始化、损失和实际训练预算不同，属于系统性能比较而非等预算模块消融。

5.4 评价指标

本文采用总体准确率（OA）、平衡准确率（BA）、宏平均 F1 及负对数似然（NLL）评价分类性能。OA 为全部样本的正确分类比例；BA 为各纳入类别召回率的平均，用于补充类别不平衡条件下的总体表现；宏 F1 对各类 F1 等权平均；NLL 衡量真实类别预测概率的质量。四分类任务的 OA、BA 和宏 F1 均针对相同的四类测试集合计算。

重复训练报告均值与样本标准差，配对收益采用船级重采样区间。进一步统计完整模型相对对照的纠错和误伤，结合逐类、逐场景及原图案例分析收益来源。同一观测在不同种子中的预测翻转分别计为事件，独立船舶数量另行统计。

5.5 比较与机制评价

普通双极化 ResNet-50 用于衡量整体增益，匹配位置 SE 用于比较一般通道重标定与类别、区域证据处理的差异。表 9 还为极化交互方法 CPINet[4]、结构建模方法 SCRC-Net[13] 以及同源参考类原型设置对照行，分别考察极化融合、目标结构及源参考信息的作用。比较统一源标签权限、输入和测试集合，各方法的超参数仅在验证集选择。

完整训练消融分别移除 CRFB、RGRP 或 RCEW，检验组件在其余网络可重新适配时的增量。RGRP 删除同时移除区域读出及响应引导接口，其余组件删除仅移除对应反馈或参考路径。

算子机制实验固定上游表征，比较区域读出、参考消息形式及末阶段优化；同权重替换仅改变取证或回写关系，定位当前预测所依赖的证据。这些结果用于解释模块作用，与共同起点的完整训练结果分开分析。

实验围绕三个层面展开：首先以共同起点比较整体分类能力，并单独考察扩大可训练范围后的性能；其次通过配套重训与算子替换分析各组件的增量；最后固定模型，对响应位置、参考回写和检测几何进行受控改变，检验模型实际利用的证据。训练种子、参考抽样和同一模型的路径干预分别作为不同的重复来源，不将其合并为独立训练次数。

6 结果与分析

6.1 跨场景分类与强基线比较

表 9 包含两类比较。分阶段完整模型、普通骨干与匹配位置 SE 采用共同预训练起点和配套优化，用于检验整体证据组织的作用；R50-Tuned、CPINet[4] 与完整模型微调版采用第 5.3 节各自的训练方案，用于比较相同数据权限下的系统性能。所有已列结果采用相同测试观测与原始极化可用性，不把输入恢复后的结果混入本表。优化范围与成本进一步见第 6.13 节。

表 **9** 相同数据评价协议下的跨场景分类结果，三种子均值与标准差。各方法训练方案见第 **5.3** 节。

数据集	方法	OA（%）	BA（%）	宏 F1（%）
OSS2	普通骨干（分阶段）	55.908 ± 1.332	52.176 ± 1.506	50.173 ± 1.359
OSS2	SE（分阶段）	54.233 ± 0.954	53.497 ± 1.802	49.862 ± 1.323

数据集	方法	OA（%）	BA（%）	宏 F1（%）
OSS2	CPINet [4]，独立复现	56.261 ± 1.986	56.988 ± 0.960	52.413 ± 1.482
OSS2	SCRC-Net [13]	—	—	—
OSS2	同源参考类原型	—	—	—
OSS2	R50-Tuned	63.051 ± 2.138	57.631 ± 2.625	55.929 ± 1.862
OSS2	本文（分阶段）	61.023 ± 2.610	55.630 ± 3.498	54.020 ± 3.267
OSS2	本文（全骨干微调）	**64.727 ± 2.702**	**59.396 ± 3.831**	**57.693 ± 3.187**
自建 24 港	普通骨干（分阶段）	42.927 ± 0.620	40.172 ± 1.041	38.385 ± 0.784
自建 24 港	SE（分阶段）	42.309 ± 0.523	41.218 ± 0.668	38.742 ± 0.693
自建 24 港	CPINet [4]	—	—	—
自建 24 港	SCRC-Net [13]	—	—	—
自建 24 港	同源参考类原型	—	—	—
自建 24 港	本文（分阶段）	**48.412 ± 1.203**	**43.902 ± 0.654**	**42.459 ± 0.937**
自建 24 港	本文（全骨干微调）	—	—	—

在共同起点的分阶段比较中，完整模型在 OSS2 中相对普通骨干的平均 OA 提高 5.115 个百分点，BA 提高 3.454 个百分点。相对普通骨干和 SE 的 OA 增量船级 95% 区间分别为 [1.422,8.642] 和 [2.814,10.908] 个百分点，BA 增量区间包含零。区间采用类别分层的配对船级 bootstrap，共 3000 次，刻画测试船舶上的抽样不确定性。

扩大可训练范围后，完整模型的 OA 和 BA 达到 64.727% 和 59.396%，相对其分阶段版本提高 3.704 和 3.766 个百分点。相对 R50-Tuned 平均提高 OA 1.675、BA 1.765 个百分点，三个种子的 OA 均更高；两项增量的船级 95% 区间分别为 [−1.243,4.674] 和 [−1.558,5.177] 个百分点。结果说明骨干与证据模块联合优化后仍具有平均净收益，但系统间差异同时包含训练历史与损失设计，组件归因由后续配套消融承担。

在自建 24 港八分类任务中，完整模型相对普通骨干的 OA、BA 和宏 F1 分别提高 5.485、3.730 和 4.074 个百分点，相对 SE 分别提高 6.103、2.684 和 3.716 个百分点。三个训练种子的 OA 和 BA 均优于两种对照，说明完整证据组织方式的收益能够延续到类别更细、场景覆盖更广的自建数据。以 MMSI 为簇对配对差进行 1000 次重采样，完整模型相对普通骨干的 OA 与 BA 增量 95% 区间分别为 [3.98,7.03] 和 [1.87,5.44] 个百分点，相对 SE 分别为 [4.66,7.66] 和 [1.08,4.53] 个百分点。上述区间保留同船重复观测的关联，描述固定模型在当前测试船舶上的抽样不确定性。

图 10 占位：完整模型纠错案例。

6.2 分阶段训练的组件消融

表 10 在 OSS2 中分别移除一个组件，保留其余结构、共同起点和训练阶段，并重新训练。删除 RGRP 同时取消相应区域读出及引导接口，删除 CRFB 或 RCEW 则移除对应反馈或参考路径。

表 **10** 分阶段训练协议下的组件删除重训，三种子均值与标准差。

数据集	配置	OA（%）	BA（%）
OSS2	无 CRFB	60.670 ± 1.305	**56.554 ± 1.239**
OSS2	无 RGRP	56.261 ± 0.666	52.164 ± 0.744
OSS2	无 RCEW	**61.023 ± 0.929**	56.477 ± 0.991
OSS2	完整模型	**61.023 ± 2.610**	55.630 ± 3.498
自建 24 港	无 CRFB	—	—
自建 24 港	无 RGRP	—	—
自建 24 港	无 RCEW	—	—

数据集	配置	OA（%）	BA（%）
自建 24 港	完整模型	48.412 ± 1.203	43.902 ± 0.654

RGRP 的贡献最明确：完整模型相对无 RGRP 的 OA/BA 提高 4.762/3.466 个百分点，三个种子均为正，OA 船级 95% 区间为 [1.046,8.444] 个百分点。化学品 / 成品油轮和集装箱船召回分别提高 6.827 和 6.569 个百分点，表明区域取证有效补充了这两类的判别信息。

CRFB 和 RCEW 的完整重训增量较小，二者的作用进一步通过对应关系替换及消息形式比较分析。对同一完整模型开启 RCEW，OSS2 平均 OA 变化为 +1.235 个百分点、BA 为 −0.136 个百分点，合计 40 次纠错和 26 次误伤。路径贡献与删除后重训的差别表明，需要结合具体证据利用过程解释组件效用。

6.3 响应引导区域池化

保持上游、参考库和样本流一致，比较区域均值补充、从局部内容新学习注意的补充、以及复用 CRFB 类别响应的补充。均值对照重复四份均值摘要以匹配接口，内容注意另有 4096 个评分参数；其有效表达能力和初始化来源仍有差别，比较首先检验已有类别响应是否值得复用。

表 **11 OSS2** 测试集上的区域读出比较，固定上游、三次末阶段训练。

读出方式	OA（%）	BA（%）	NLL
增加补充读出前的固定上游	62.434	59.718	1.14782
区域均值补充	61.464 ± 0.305	58.233 ± 0.710	1.14277
普通内容注意补充	61.464 ± 0.666	58.050 ± 0.674	1.14460
CRFB 响应引导 RGRP 补充	**62.346 ± 0.153**	**59.781 ± 0.220**	**1.14005**

响应引导相对均值补充的 OA/BA 分别提高 0.882/1.548 个百分点，三个种子均为正；相对内容注意提高 0.882/1.731 个百分点。相对固定上游则为 −0.088/+0.063 个百分点，表明类别响应在新增区域读出中更有效地保留了原有判别能力。验证集三个方案的平均 OA/BA 均为 62.281%/55.731%。

6.4 正确空间对应是否参与判断

在响应引导模型权重固定时，将区域内部权重改成均匀值，或反向置换非空位置的权重。均匀替换保持归一化总量但改变权重分布；位置置换同时保持总量与直方图，仅改变权重与局部特征的对应。

表 **12** 同权重取证方式替换，**OSS2** 测试集 **378** 条。

取证方式	OA（%）	BA（%）
正确响应位置	62.346	59.781
区域内均匀权重	61.464	57.753
区域内位置置换	60.758	57.297
关闭新增读出	62.169	58.796

正确响应相对位置置换平均提高 OA 1.587、BA 2.484 个百分点，表明该测试队列中的正确权重—特征对应实际参与分类。响应引导相对配套均值模型共有 10 次纠错、0 次误伤，涉及 7 条观测、7 艘船和 3 个过境；其中 9 次在增加读出前已正确，所以主要作用是减少不合适读出适配造成的损失。

图 11 中普通货船 000133 的真实类分差，在均值读出下为 −0.06155，响应引导下为 +0.22820；同权重均匀替换和位置置换后分别为 −0.06187 与 −0.13565。该样本关闭新增读出时仍正确，说明优

势来自更合适的区域取证。线性分解中，VV 框内、轴端与侧向对普通货船相对油轮的优势贡献分别约 +0.0860、+0.0449 和 +0.1778，VH 三项为负，体现了极化及区域作用的差异。

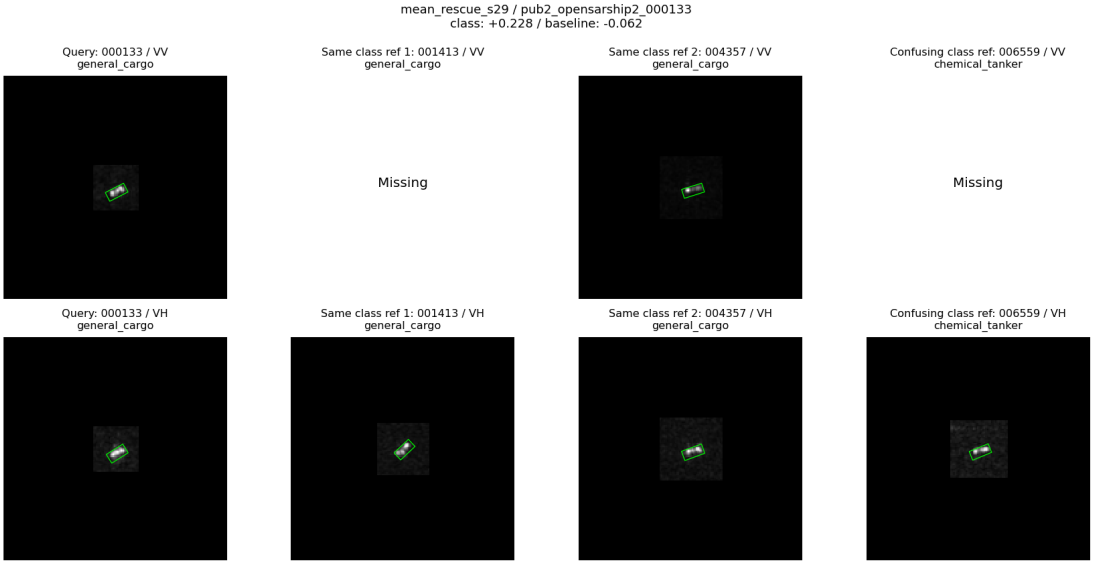


图 11 普通货船 000133 及合法参考的 VV/VH 图像。baseline 为均值读出对照；Missing 表示该极化未通过输入有效性筛选。图像按原生尺度裁剪或补零。

6.5 参考证据的消息形式

在固定前端的独立 RCEW 实验中，三组配对训练使用相同源数据、查询 / 参考 episode 和 120 步预算，仅更新相应参考模块及分类头。表 13 采用相同训练长度下的末轮结果。

表 **13 RCEW** 独立训练的验证集比较，固定前端、三种子平均。

方案	OA（%）	BA（%）
无 RCEW，更新分类头	58.626 ± 0.253	50.017 ± 0.162
普通参考特征回写	58.772 ± 0.439	50.119 ± 0.281
类别证据回写，精细对应	60.234 ± 1.410	51.830 ± 0.852
类别证据回写，保留边际聚合	**61.257 ± 2.251**	**53.511 ± 2.442**

聚合证据回写相对无 RCEW 提高 OA/BA 2.632/3.495 个百分点，相对普通参考特征回写提高 2.485/3.392 个百分点。普通参考特征回写仍保留类别、区域和极化组织，因此这一比较不只是 “有类别信息” 对 “完全无组织信息”。图 12 的集装箱船 000867 在三个种子中均被类别证据回写判对，而普通参考回写、无 RCEW 和其自身关闭回写均错。seed17 的真实类分差由无 RCEW 的 −0.334、参考特征回写的 −0.286 变为 +0.275，构成直接路径案例。

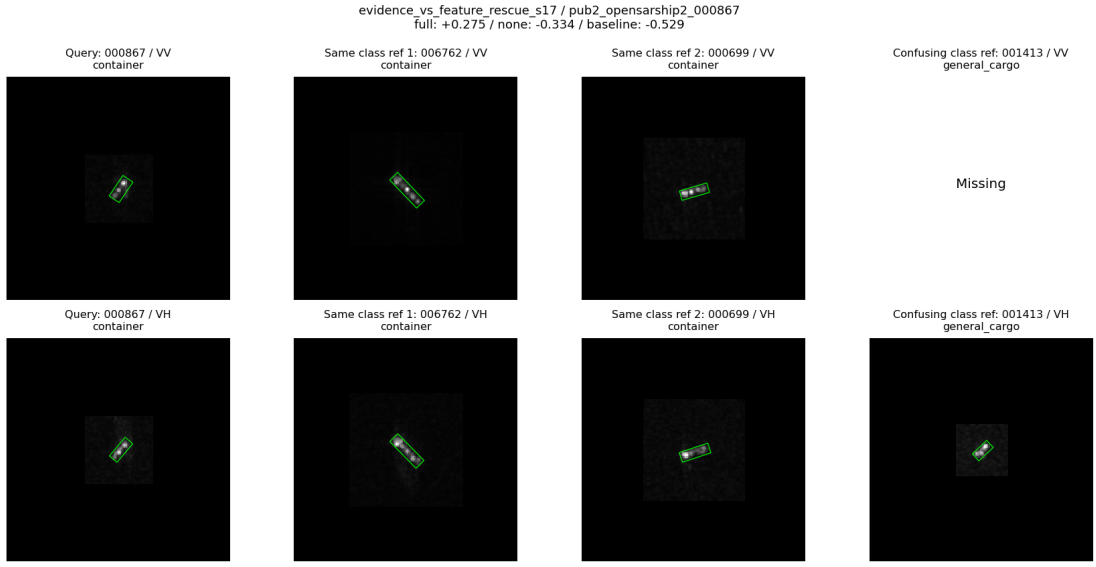


图 12 集装箱船 000867 及同类、混淆类参考。full 为类别证据回写，none 为关闭参考模块，baseline 为图示原始基线。样本在三次训练中均由类别证据回写判对。

图 13 进一步呈现参考信息进入查询特征的空间路径。在早期空间回写配置的八分类、16 源参考诊断中，Jebel Ali 散货船 12457 的真实类分差由关闭回写时的 −0.836 变为 +0.138；移除 VH 整路回写后降至 −0.486，单独移除 VH 框内回写后为 −0.250。该路径干预将分类变化定位到实际回写响应，而非仅凭匹配热图解释。

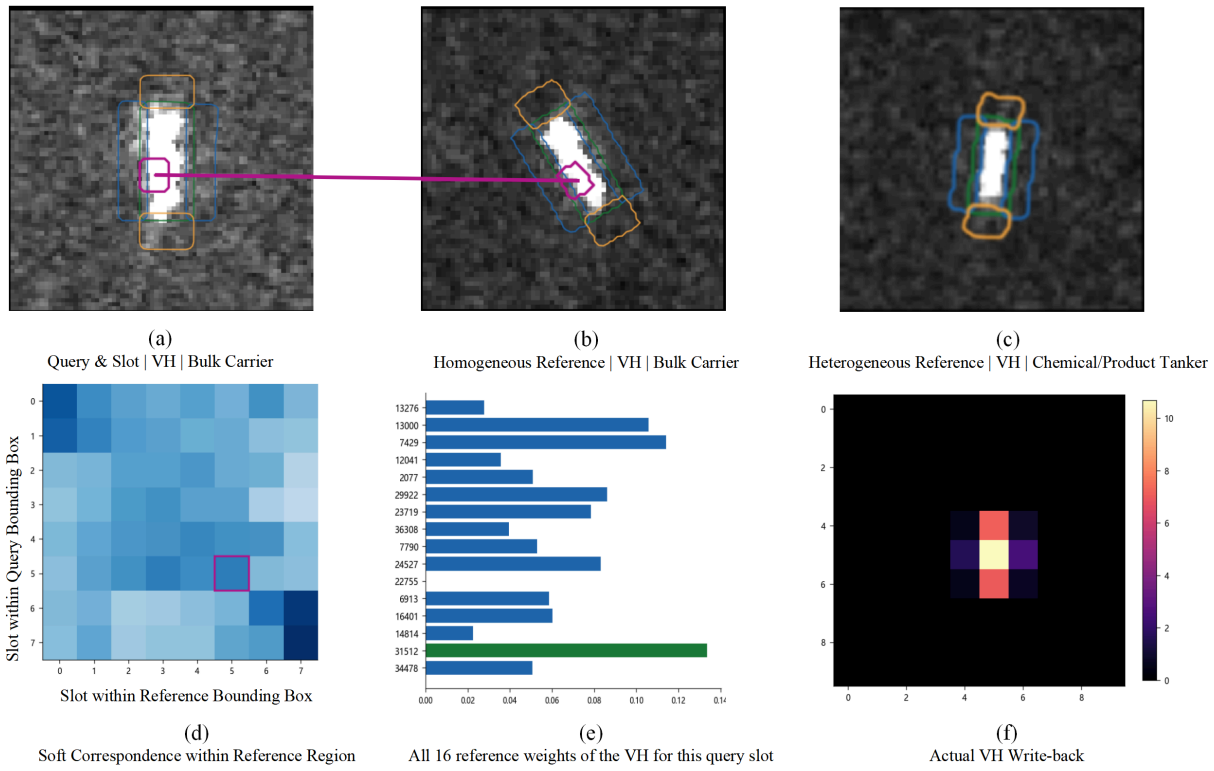


图 13 空间参考回写的路径诊断。上方为散货船 12457、同类参考 31512 与混淆类参考 13000 的 VH 图像及区域位置，下方为局部软对应、16 个参考的聚合权重和查询回写强度。该图取自早期空间回写配置，展示参考比较至特征更新的过程；当前类别证据回写的效果见图 12。

对精细对应模型保持权重并改用边际聚合，三个种子、228 条查询的预测均不变；配套训练的聚合版平均表现更好。保留类别关系与参考选择后，区域聚合已能提供有效的回写消息。

在全骨干微调模型上，进一步固定权重、原图和 32 个源参考，对实际聚合回写路径进行干预。原路径的 OA / BA 为 64.727% / 59.396%，同权重关闭回写为 64.374% / 59.702%，使用简单类别均值替代为 64.109% / 58.664%。原路径相对简单均值平均提高 OA 0.617、BA 0.732 个百分点；相对无回写则出现 OA 小幅提高、BA 小幅降低，反映收益在类别间的不同分配。该比较定位已训练路径的作用，不等同于删除模块后重新训练。

对应案例中，查询 002422（seed29）的真实类分差为 +0.0928，改用简单类别均值后为 −0.0769，撤除框内回写后为 −0.0545，说明该样本需要当前框内证据组织才能越过判别边界。对图 13 的历史样本 12457，撤除 VV 或 VH 轴端回写分别将分差从 +0.13756 降至 +0.10698 或 +0.10911，仍保持正确。这一区别表明局部回写既可能决定预测翻转，也可能只增加已有判断的余量；更新热图的幅度与其分类贡献需结合路径撤除共同解释。

6.6 固定上游下的参考与读出协同

固定相同上游，移除 RCEW 残差后重新计算 layer4 与深层区域摘要，再以相同初始化、源样本顺序和 180 步预算训练区域补充及分类头。保留 RCEW 的组合沿用表 11 结果。此对照比较固定上游条件下、有无参考证据时的配套末阶段优化，不等同于表 10 的共同起点完整重训。

表 **14** 固定上游下有无 **RCEW** 的末阶段配套训练比较。

队列	配置	OA（%）	BA（%）	NLL
验证集 228	无 RCEW 配套训练	61.404 ± 0.439	54.581 ± 0.287	1.23567
验证集 228	保留 RCEW	62.281 ± 0.439	55.731 ± 0.284	1.23337
测试集 378	无 RCEW 配套训练	61.993 ± 0.808	59.020 ± 0.951	1.14967
测试集 378	保留 RCEW	62.346 ± 0.153	59.781 ± 0.220	1.14005

RCEW 在验证集与测试集上的平均 OA/BA 增量分别为 +0.877/+1.149 和 +0.353/+0.760 个百分点。测试集三个种子的 NLL 均下降，平均降低 0.00963，说明在该固定上游和配套读出设置下，参考证据能提供小幅净收益。

测试集三次训练合计 13 次纠错与 9 次误伤，涉及 8 艘与 6 艘船。集装箱船 002950 在 seed17 下的真实类分差由无 RCEW 配套模型的 −0.07493 提高至 +0.36983，同权重关闭回写亦会误判。这一案例将参考证据的作用落实为正确类相对竞争类的优势恢复。

6.7 计算成本与推理加速

计算成本在 RTX 5050 Laptop GPU（8 GB）上测量，采用 FP32、关闭 TF32，输入为双极化 160×160 chip。计时覆盖 GPU 上的图像及掩膜到分类分数的完整前向，不含检测、文件读取和 CPU 预处理。完整模型缓存 32 个源参考描述子，并将 RCEW 固定形状的 60 步传输迭代捕获为 CUDA Graph。延迟均在预热后测量并取中位数：普通骨干和 SE 各三组、每组 15 次，完整模型各三组、每组 10 次。

表 **15** 分阶段四分类模型的在线计算成本。运算量仅统计卷积与矩阵乘，一次乘加计两次操作。

方法	参数（M）	运算量（G）	延迟（ms）	显存（MiB）
普通骨干	23.524	8.342	6.51	158.7
匹配位置 SE	23.690	8.343	7.50	161.5
CPINet	—	—	—	—
SCRC-Net	—	—	—	—
同源参考类原型	—	—	—	—
本文完整模型	25.053	8.673	49.37	—

参数量统计实际执行的网络参数，显存为 PyTorch 在线分配峰值。完整模型增加 6.50% 的执行参数和 3.96% 的卷积 / 矩阵乘运算量；后者未覆盖归一化及传输迭代等操作。参考缓存占 3.755 MiB，一次构建耗时 43.43 ms。

完整模型的单张稳态延迟为 49.37 ms；批量 8 的整批延迟为 63.87 ms，吞吐达 125.3 张/s。图重放不改变模型权重和数值精度，OSS2 同一种子的 378 条预测类别全部保持一致。稳态计时不含参考库构建和一次性图初始化；单张配置的图初始化约 0.683 s。

6.8 核心算子的配套替换

表 16 进一步分解 CRFB 的均值反馈与类别关系反馈，以及 RCEW 的通道度量与类别竞争偏置。CRFB 对照保留类别响应读出、辅助监督及 RGRP 引导接口，仅关闭指定反馈支路；因此无反馈配置不同于表 10 的整块删除。RCEW 的单位度量对照将通道权重固定为 1，无竞争偏置对照将相应项置零，其余参考比较和回写路径保持不变。各配置从对应机制启用前的共同检查点开始，重新训练受影响阶段及后续阶段；训练步数、源参考成员和样本顺序保持一致，干预与源难例权重沿用相同生成规则。已有表 11—14 的固定上游结果与本表分开比较。

表 **16** 核心算子替换的测试集结果。各数据集单元格为三种子平均 **OA** / **BA**（**%**），破折号为待填结果。

组件	替换方式	OSS2	自建 24 港
CRFB	无反馈，保留响应读出	60.670 / 55.897	—
CRFB	仅均值反馈	60.935 / 55.606	—
CRFB	仅类别关系反馈	60.317 / 55.619	—
CRFB	均值＋类别关系反馈	61.023 / 55.630	—
CRFB	普通内容注意反馈	—	—
RGRP	仅框内池化	—	—
RGRP	同范围内外合并池化	60.847 / 57.221	—
RGRP	保留内部区域，仅合并最终读出	61.640 / 58.086	—
RGRP	分区域池化，仅末端读出	—	—
RGRP	分区域池化，内部回写＋末端读出	61.023 / 55.630	48.412 / 43.902
RCEW	无参考回写	—	—
RCEW	普通参考特征回写	—	—
RCEW	参考类别证据回写	61.023 / 55.630	48.412 / 43.902
RCEW	单位通道度量，无竞争偏置	60.847 / 56.060	—
RCEW	学习通道度量，无竞争偏置	61.199 / 56.311	—
RCEW	单位通道度量，保留竞争偏置	60.847 / 56.716	—
RCEW	学习通道度量＋竞争偏置	61.023 / 55.630	—

CRFB 双反馈相对仅均值反馈的平均 OA 和 BA 分别提高 0.088 和 0.024 个百分点，相对仅类别关系反馈的 OA 提高 0.705 个百分点、BA 基本持平。均值与关系分支的组合能够保留部分边界样本的判别优势，但本设置下额外平均收益较小。该结果与表 11 的响应引导收益对应不同作用位置：前者衡量中间特征反馈，后者衡量类别响应在区域取证中的复用。

RGRP 的区域身份比较保持图像覆盖范围和局部处理路径不变。保留内部区域回写、仅合并最终读出，相对内外全部合并提高 OA 0.794、BA 0.865 个百分点，三个种子的 BA 均提高；相比之下，最终三区域读出并未在测试集上优于合并读出。因此，RGRP 相对整块删除的收益来自局部取证与回

写的组合，内部区域组织具有增量，而不宜把全部收益归因于最终描述中的三区域区分。原区域配置在验证集上的 BA 为 57.582%，高于仅合并最终读出的 53.572%，模型选择仍沿用验证集结果。

RCEW 在关闭竞争偏置时，学习通道度量相对单位度量提高 OA 0.353、BA 0.250 个百分点，三个种子的 BA 增量均为正。加入竞争偏置后，平均 OA 和 BA 分别较仅通道度量下降 0.176 和 0.681 个百分点，说明两个机制的收益并非简单相加。因而，类别比较与参考回写的有效性应结合表 13—14 的消息形式和路径对照解释，而不能仅以内部组件数量说明优势。

6.9 极化处理方式

极化参数比较保持共享 ResNet-50 骨干、模块位置、训练阶段及输入可用性不变，仅改变极化对应模块的参数绑定方式。每个种子先把 VV 初始化复制给 VH，使共享组与专属组从相同初始函数出发；两组均完成 736 次更新并使用配对的样本顺序。参数共享作用于 CRFB、RGRP 的可训练变换及 RCEW 的极化对应变换，原本共用的度量部分保持不变。两组使用相同 378 条测试观测，而非分别挑选可用样本。

表 **17** 极化输入与参数组织比较。各数据集单元格为 **OA** / **BA**（**%**）。

输入	参数组织	OSS2	自建 24 港
VV	单极化配套训练	—	—
VH	单极化配套训练	—	—
VV + VH	共享骨干、共享模块	59.965 / 53.971	—
VV + VH	共享骨干、极化专属模块	**61.376** / **56.252**	—
VV/VH 通道堆叠	早期融合	—	—

极化专属参数相对共享参数提高 OA 1.411、BA 2.281 个百分点，三个种子的 BA 均提高；在两路均可用的 348 条子集中，仍提高 OA 0.766、BA 1.514 个百分点。普通货船召回提高 6.410 个百分点，是主要 BA 收益来源。该结果支持共享通用骨干、允许极化相关证据变换分别学习的组织方式；它评价的是整体参数策略，包含新增参数容量的作用，而非证明每个模块都必须独立处理两种极化。

针对一侧未获得有效 OBB 的输入，另固定微调完整模型与原参考，在核实两极化裁片共用地理格网后，用可用极化的目标框恢复另一视图。OSS2 的 30 条单路测试观测均具有对应原图，恢复后全测试 OA 由 64.727% 提高至 65.344%，BA 由 59.396% 变为 59.430%。这一输入恢复结果单独报告，说明定位可用性会影响识别，但不把缺失极化作为所有误分类的共同解释。

6.10 源参考库规模与抽样

表 18 固定模型权重、查询集合和合法源候选池，每个预算进行五次配对参考抽样，考察部署时更换参考库的敏感性。预算按每类独立船数计，总参考数随类别数变化；抽样标准差与训练种子标准差分别报告。参考均来自训练集，不使用目标标签，且不同预算不改变测试集类别组成。

表 **18** 冻结模型的源参考预算比较。每格 **OA**、**BA** 为五次参考抽样的均值与标准差；延迟包含参考比较。

数据集	每类船数 / 总参考数	OA（%）	BA（%）	NLL	延迟（ms）
OSS2	1 / 4	—	—	—	—
OSS2	2 / 8	—	—	—	—
OSS2	4 / 16	—	—	—	—
OSS2	8 / 32	—	—	—	—
OSS2	16 / 64	—	—	—	—
自建 24 港	1 / 8	—	—	—	—
自建 24 港	2 / 16	—	—	—	—
自建 24 港	4 / 32	—	—	—	—
自建 24 港	8 / 64	—	—	—	—
自建 24 港	16 / 128	—	—	—	—

6.11 干预指导训练

表 19 在完整训练的干预适配阶段替换选样方式，再执行相同的参考、类别反馈和区域读出训练。普通适配仅使用原图分类监督与教师正确样本的分布保持；随机选样与干预选样使用相同判别优势保护，并按类别匹配选样数量。比较保持更新参数、训练预算和后续阶段一致，检验选样机制对最终分类的作用。

表 **19** 完整训练路径内的干预指导对照。各数据集单元格为三种子平均 **OA** / **BA**（**%**）。

适配方式	判别优势保护对象	OSS2	自建 24 港
普通适配	无	60.141 / 54.866	—
类内配额随机选样	随机选中的源样本	60.141 / 55.297	—
干预有效性选样	通过干预筛选的源样本	**61.023** / **55.630**	—

干预选样相对类内配额随机选样提高 OA 0.882、BA 0.333 个百分点，三个种子的 OA 均提高；相对无分差保护提高 OA 0.882、BA 0.764 个百分点。前一比较在五个测试过境中有四个取得平均 OA 增量，说明收益不只出现在单个场景。其船级配对 OA 增量 95% 区间为 [−0.440,2.216] 个百分点，故这一结果支持小幅净收益，不作显著提升判断。

三种策略均训练全部源图像，只改变额外分差保护的分配。干预筛选的保护项在各 96 步适配中有 89、88、90 步非零，确认约束实际参与优化。化学品 / 成品油轮 000141 在两个种子中被干预选样模型救回；seed17 下，相对随机选样的真实类分差由 −0.678 提高至 +0.176。该例说明样本保护能通过后续完整训练转化为判别改善，而非要求预测时修改输入图像。

6.12 分场景表现与定位鲁棒性

表 20 按过境和港口汇总分阶段完整模型相对普通骨干的配对增量，保留不同场景的类别覆盖；场景 BA 仅在该组实际存在的类别上计算。表中平均增量先在每个场景内对三个训练种子取均值，再对场景等权汇总，不同于表 9 按全部测试观测统计的 OA。自建数据的过境统计采用包含 datatake 的 85 个完整过境组。定位鲁棒性另固定图像和标签，仅改变 OBB 并重新生成局部区域，避免把输入像素变化与区域组织误差混为一谈。

表 **20** 场景级增量分布。增量相对普通骨干，以百分点计；正 / 平 / 负为场景数。

数据集 / 分组	场景数	平均 ΔOA	平均 ΔBA	OA 正 / 平 / 负
OSS2 / 过境	5	+5.199	+7.322	4 / 0 / 1
自建 24 港 / 过境	85	+3.813	+2.183	58 / 3 / 24
自建 24 港 / 港口	18	+1.876	+0.088	12 / 0 / 6

完整模型在自建数据的 12 个港口和 58 个完整过境组中取得平均 OA 增益，其中 10 个港口、35 个过境组在三个种子中均提高。Port Klang、Santos 与 Richards Bay 相对普通骨干的 OA 分别提高 6.52、10.04 和 9.91 个百分点，说明收益分布于多个水域。场景内的类别构成仍会影响增量：Singapore 的 OA 提高 6.49 个百分点，而 BA 下降 3.72 个百分点；Jebel Ali 的 OA 下降 0.16 个百分点，BA 提高 1.24 个百分点。因此，跨场景净收益与各场景内部的类别收益分配需要分别评价。这里的逐港统计基于同一跨场景划分，不等同于留一港训练。

表 **21** 固定分阶段模型的 **RGRP** 定位扰动结果。**OSS2** 使用相同 **378** 条查询，单元格为三种子平均 **OA** / **BA**（**%**）。

比较类型	输入条件	OSS2	自建 24 港
基准	原始 OBB	61.023 / 55.630	—

比较类型	输入条件	OSS2	自建 24 港
中心位置	沿轴 −20% / +20%	62.346 / 57.338；60.317 / 55.678	—
中心位置	横轴 −20% / +20%	61.728 / 55.681；60.406 / 54.870	—
长宽尺度	等比 −20% / +20%	58.995 / 56.057；62.610 / 56.221	—
长度	−20% / +20%	59.524 / 56.324；62.434 / 56.061	—
宽度	−20% / +20%	60.141 / 55.369；60.317 / 55.245	—
轴向角度	−20° / +20°	61.464 / 56.936；61.993 / 55.768	—
定位扰动	缺框回退	—	—

中心位移分别按框长和框宽归一化，并比较 5%、10%、20% 的正负偏移；尺寸改变包括 10%、20% 的独立长宽及等比变化，角度比较正负 5°、10°、20°，合计 30 个非零条件与零扰动。表 21 列出各变量的最大幅度，较小扰动保留相同定义。所有条件只更新查询的 RGRP 局部区域，图像像素、参考描述及 RCEW 回写保持固定，因此衡量的是区域定位敏感性，而不是整个检测流程的误差传播。

30 个非零条件的平均 OA 变化为 −2.028 至 +1.587 个百分点，BA 变化为 −0.760 至 +1.708 个百分点。缩框和扩框产生不同类别权衡：等比缩小 20% 使集装箱船平均召回降低 7.056 个百分点、化学品 / 成品油轮提高 8.434 个百分点。故小幅总体变化并不代表每个预测不变，扩大范围也不是统一最优策略。该实验保留原框作为评价基准，不根据测试扰动择优修改输入。

6.13 优化范围与训练成本

表 22 列出分阶段完整模型与两种全骨干配置的优化结果，验证集用于选择范围、学习率与检查点，测试性能见表 9。完整模型微调不改变模块位置、参考数量和原始输入权限，改善来自新增联合优化而非增加测试信息。

表 **22 OSS2** 训练方案与验证集性能。轮数按 **seed17 / 29 / 43** 排列；**OA / BA** 为三种子平均（**%**）。

配置	初始化	实际轮数	验证 OA / BA
本文分阶段版	ImageNet	五阶段固定预算	63.304 / 57.582
R50-Tuned	ImageNet	46 / 49 / 53	64.035 / 61.110
本文全骨干微调	对应分阶段终点	23 / 19 / 22	65.936 / 61.224

完整模型三个微调运行共新增 1,920 次更新，连同继承的三次分阶段训练合计 4,128 次；R50-Tuned 三个运行共 4,440 次更新。两者的源图像暴露次数分别为 96,356 和 106,412，均为重复训练暴露而非独立样本数。完整模型还包含参考前向、辅助监督与历史分阶段学习，更新次数不能直接换算为相同计算量。这些预算与表 15 的稳态推理延迟分别报告，以区分训练投入和部署开销。

6.14 逐类识别表现

表 23 给出表 9 分阶段完整模型的逐类召回及相对普通骨干的变化，用于区分总体改善与类别间收益分配。公开集四类之外的单元格标为不适用，不参与其 BA 或宏 F1 计算。误差分析结合实际查询及同类、混淆类参考，沿用图 11—13 的响应、局部替换与回写路径诊断。

表 **23** 完整模型的逐类召回。单元格为召回率（**%**）及相对普通骨干的增量（百分点）。

船型	OSS2	自建 24 港
散货船	53.54（+3.54）	63.46（+11.19）
普通货船	35.90（−3.85）	40.75（+7.20）
化学品 / 成品油轮	58.63（+6.83）	42.76（+2.53）
集装箱船	74.45（+7.30）	43.49（+1.94）
渔船	不适用	65.69（+2.29）
原油轮	不适用	48.44（+3.39）

船型	OSS2	自建 24 港
拖轮 / 拖带船	不适用	14.49（−1.69）
海工补给船	不适用	32.14（+2.99）

在自建数据中，八类中的七类相对普通骨干取得平均召回增益，其中散货船与普通货船分别提高 11.19 和 7.20 个百分点。散货船有 947 条测试观测，贡献约 62.85% 的净 OA 增量；其余类别合计仍贡献正增量，且 BA 同时提高，说明收益并非仅由最大类别的数量优势构成。OSS2 的化学品 / 成品油轮和集装箱船分别提高 6.83 和 7.30 个百分点，而普通货船下降 3.85 个百分点，体现了不同类别和数据条件下的作用差异。

原图回看进一步将总体结果落实到具体预测。自建数据中，Singapore 散货船样本 198 在三个种子中均由普通骨干的原油轮误判恢复为散货船；Tanger Med 普通货船样本 551 均由化学品 / 成品油轮误判恢复为普通货船。前者双极化呈细长响应，后者查询与同类参考的轴向并不一致，表明粗外形或方向一致性不足以单独解释分类。相对 SE，Jebel Ali 化学品 / 成品油轮样本 1070 也在三个种子中均被完整模型判对。上述实例与逐类、逐场景增量相互补充；具体模块的作用仍由配套消融和路径干预确定。

7 讨论

公开集、自建数据比较与机制实验形成了相互补充的证据链：分阶段配套训练检验证据组织的整体效用，全骨干微调考察表征与模块的联合适配，区域消融定位主要收益来源，权重置换及参考回写干预则解释已训练预测如何形成。三类模块分别承担特征反馈、区域汇总和跨样本比较，其局部作用与完整训练增量不作简单相加。区域身份合并、极化共享和参考替换进一步说明，整体系统有效并不要求每个内部设计在所有指标上同时占优；保留模块应依据其可重复净收益及明确作用范围。

识别正确率与预测概率质量并不完全一致。自建数据中，完整模型的 NLL 为 2.0670，高于普通骨干的 1.8320 和 SE 的 1.6081，说明正确预测增多的同时，剩余错误仍存在过度自信。本文的主要收益体现为 OA、BA 和宏 F1 的改善，概率校准可作为进一步完善方向。

参考规模、类内观测覆盖及前端表征共同影响回写效用，外围响应的物理来源可结合更精细标注继续研究。干预选样为训练提供样本级判别保护，公平比较中的各方法采用相同规则。不同港口、时相与成像条件构成联合场景变化，本文以可追溯的局部证据处理提升分类能力，不要求将所有变化压缩为单一不变表征。

8 结论

本文针对跨场景 SAR 船舶分类中局部判别证据利用不充分的问题，结合同船重复观测与受控图像干预，发现局部响应的判别作用依赖极化、区域及类别竞争。在此基础上，提出共享骨干的极化与区域证据学习网络：CRFB 将相对类别响应用于局部特征反馈，RGRP 在目标几何区域内组织多层证据，RCEW 将源参考比较转换为中间层类别证据场；训练结合干预选样与原图判别优势保护。OSS2 四分类和自建 24 港八分类的分阶段完整训练相对匹配普通骨干均取得 OA、BA 及宏 F1 增益，OSS2 全骨干微调进一步提升系统性能。配套消融显示 RGRP 具有明确的净收益，极化参数比较与干预选样对照支持差异化证据处理，内部替换与真实案例揭示类别响应和参考回写的具体作用。研究表明，按来源与区域组织局部证据，并将其同类别竞争关系结合，是改善跨场景 SAR 船舶分类的一条有效途径。

参考文献

[1] L. Huang, B. Liu, B. Li, W. Guo, W. Yu, Z. Zhang, and W. Yu. OpenSARShip: A Dataset Dedicated to Sentinel-1 Ship Interpretation. *IEEE JSTARS*, 11(1):195–208, 2018. doi:10.1109/JSTARS.2017.2755672.

[2] H. Xie, J. He, Z. Lu, and J. Hu. Two-Level Feature-Fusion Ship Recognition Strategy Combining HOG Features with Dual-Polarized Data in SAR Images. *Remote Sensing*, 15(18):4393, 2023. doi:10.3390/rs15184393.

[3] Z. Shao, T. Zhang, and X. Ke. A Dual-Polarization Information-Guided Network for SAR Ship Classification. *Remote Sensing*, 15(8):2138, 2023. doi:10.3390/rs15082138.

[4] J. He et al. CPINet: Towards A Novel Cross-Polarimetric Interaction Network for Dual-Polarized SAR Ship Classification. *Remote Sensing*, 16(18):3479, 2024. doi:10.3390/rs16183479.

[5] N. Xie, T. Zhang, W. Guo, Z. Zhang, and W. Yu. Dual Branch Deep Network for Ship Classification of Dual-Polarized SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–15, 2024. doi:10.1109/TGRS.2024.3372021.

[6] Z. Liu, K. Li, L. Wang, and Z. Zhang. Multi-Scale Alignment Domain Adaptation for Ship Classification in Multi-Resolution SAR Images. *IEEE Transactions on Automation Science and Engineering*, 22:4051–4062, 2025. doi:10.1109/TASE.2024.3407130.

[7] L. Chen, J. Li, H. Zhong, H. Shi, Z. Yang, and W. Li. PGMNet: A Prototype-Guided Multimodal Network for Ship Recognition in SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 63:5215517, 2025. doi:10.1109/TGRS.2025.3583282.

[8] R. C. Fong and A. Vedaldi. Interpretable Explanations of Black Boxes by Meaningful Perturbation. *ICCV*, 3449–3457, 2017. doi:10.1109/ICCV.2017.371.

[9] S. Hooker, D. Erhan, P.-J. Kindermans, and B. Kim. A Benchmark for Interpretability Methods in Deep Neural Networks. *NeurIPS*, 32, 2019.

[10] X. Hou, W. Ao, Q. Song, J. Lai, H. Wang, and F. Xu. FUSAR-Ship: Building a High-Resolution SAR-AIS Matchup Dataset of Gaofen-3 for Ship Detection and Recognition. *Science China Information Sciences*, 63:140303, 2020. doi:10.1007/s11432-019-2772-5.

[11] S. Zhao and H. Lang. Improving Deep Subdomain Adaptation by Dual-Branch Network Embedding Attention Module for SAR Ship Classification. *IEEE JSTARS*, 15:8038–8048, 2022. doi:10.1109/JSTARS.2022.3206753.

[12] Y. Shi, L. Du, Y. Guo, Y. Du, and Y. Li. Unsupervised Domain Adaptation for Ship Classification via Progressive Feature Alignment: From Optical to SAR Images. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–17, 2024. doi:10.1109/TGRS.2024.3458937.

[13] Y. Qi, L. Wang, C. Zhao, P. T. Mathiopoulos, T. Ohtsuki, and F. Adachi. SCRC-Net: A Structure-Constrained and Representation-Consistent Network for SAR Ship Classification. *Pattern Recognition*, 180:114294, 2026. doi:10.1016/j.patcog.2026.114294.

[14] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, "Learning Deep Features for Discriminative Localization," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 2921-2929, doi: 10.1109/CVPR.2016.319.

[15] J. Hu, L. Shen, and G. Sun, "Squeeze-and-Excitation Networks," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 7132-7141, doi: 10.1109/CVPR.2018.00745.

[16] H. Lee, H.-E. Kim, and H. Nam, "SRM: A Style-Based Recalibration Module for Convolutional Neural Networks," in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 1854-1862, doi: 10.1109/ICCV.2019.00194.

[17] Z. Gao, J. Xie, Q. Wang, and P. Li, "Global Second-Order Pooling Convolutional Networks," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 3024-3033, doi: 10.1109/CVPR.2019.00314.

[18] Y. Chen, Y. Kalantidis, J. Li, S. Yan, and J. Feng, “A^2-Nets: Double Attention Networks,” in Advances in Neural Information Processing Systems, vol. 31, 2018, pp. 352-361.

[19] Y. Cao, J. Xu, S. Lin, F. Wei, and H. Hu, “GCNet: Non-Local Networks Meet Squeeze-Excitation Networks and Beyond,” in Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), 2019, pp. 1971-1980, doi: 10.1109/ICCVW.2019.00246.

[20] J. Dai, Y. Li, K. He, and J. Sun, “R-FCN: Object Detection via Region-based Fully Convolutional Networks,” in Advances in Neural Information Processing Systems, vol. 29, 2016, pp. 379-387.

[21] X. Li, X. Wang, R. Zhu, Z. Ma, J. Cao, and J.-H. Xue. Selectively Augmented Attention Network for Few-Shot Image Classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(2):1180–1192, 2025. doi:10.1109/TCSVT.2024.3480279.

[22] J. Snell, K. Swersky, and R. Zemel, “Prototypical Networks for Few-shot Learning,” in Advances in Neural Information Processing Systems, vol. 30, 2017, pp. 4077-4087.

[23] W. Li, L. Wang, J. Xu, J. Huo, Y. Gao, and J. Luo, “Revisiting Local Descriptor Based Image-To-Class Measure for Few-Shot Learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 7260-7268, doi: 10.1109/CVPR.2019.00743.

[24] R. Hou, H. Chang, B. Ma, S. Shan, and X. Chen, “Cross Attention Network for Few-shot Classification,” in Advances in Neural Information Processing Systems, vol. 32, 2019, pp. 4003-4014.

[25] C. Zhang, Y. Cai, G. Lin, and C. Shen. DeepEMD: Few-Shot Image Classification With Differentiable Earth Mover’s Distance and Structured Classifiers. *CVPR*, 12203–12213, 2020.

[26] D. Wertheimer, L. Tang, and B. Hariharan, “Few-Shot Classification With Feature Map Reconstruction Networks,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 8012-8021, doi: 10.1109/CVPR46437.2021.00792.

[27] J. Wu, D. Chang, A. Sain, X. Li, Z. Ma, J. Cao, J. Guo, and Y.-Z. Song. Bi-Directional Ensemble Feature Reconstruction Network for Few-Shot Fine-Grained Classification. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(9):6082–6096, 2024. doi:10.1109/TPAMI.2024.3376686.

[28] W. Li, W. Yang, L. Liu, W. Zhang, and Y. Liu. Discovering and Explaining the Noncausality of Deep Learning in SAR ATR. *IEEE GRSL*, 20:1–5, 2023. doi:10.1109/LGRS.2023.3266493.

[29] D. Yin, R. G. Lopes, J. Shlens, E. D. Cubuk, and J. Gilmer. A Fourier Perspective on Model Robustness in Computer Vision. *NeurIPS*, 32, 2019.

[30] A. S. Ross, M. C. Hughes, and F. Doshi-Velez. Right for the Right Reasons: Training Differentiable Models by Constraining Their Explanations. *IJCAI*, 2017.

[31] Z. Huang, H. Wang, E. P. Xing, and D. Huang, “Self-challenging Improves Cross-Domain Generalization,” in Computer Vision - ECCV 2020, Lecture Notes in Computer Science, vol. 12347, 2020, pp. 124-140, doi: 10.1007/978-3-030-58536-5_8.

[32] A. S. Ross and F. Doshi-Velez, “Improving the Adversarial Robustness and Interpretability of Deep Neural Networks by Regularizing Their Input Gradients,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 32, no. 1, 2018, pp. 1660-1669, doi: 10.1609/aaai.v32i1.11504.

[33] P. Chattopadhyay, K. Sarangmath, V. Vijaykumar, and J. Hoffman. PASTA: Proportional Amplitude Spectrum Training Augmentation for Syn-to-Real Domain Generalization. *ICCV*, 19288–19300, 2023.

[34] H. Cheng, S. Yang, J. T. Zhou, L. Guo, and B. Wen. Frequency Guidance Matters in Few-Shot Learning. *ICCV*, 11814–11824, 2023.

[35] Y. Wang, F. Liu, Z. Chen, Y.-C. Wu, J. Hao, G. Chen, and P.-A. Heng. Contrastive-ACE: Domain Generalization Through Alignment of Causal Mechanisms. *IEEE Transactions on Image Processing*, 32:235–250, 2023. doi:10.1109/TIP.2022.3227457.

[36] K. He, X. Zhang, S. Ren, and J. Sun. Deep Residual Learning for Image Recognition. *CVPR*, 770–778, 2016.